

Analyse de sensibilité dans les systèmes feed-forward

Bibliographie – Rapport de stage

Ugur Kul

Encadré par :

Mohamed Reda El Amri
Adrien Spagnol

Table des matières

1	Introduction	3
2	Analyse de sensibilité globale d'un système entrée-sortie simple	5
2.1	Sous l'hypothèse d'indépendance des entrées	5
2.1.1	Méthode de Morris	5
2.1.2	DGSM	6
2.1.3	Décomposition de Hoeffding	6
2.1.4	Indices de Sobol	7
2.1.5	Méthode Pick-Freeze	8
2.2	Sous dépendance	8
2.2.1	Éléments de théorie des jeux	8
2.2.2	Indices de Sobol-Shapley	9
2.2.3	Estimation par permutations	9
2.2.4	Distance covariance et distance corrélation	10
2.3	Hilbert-Schmidt Independence Criterion (HSIC)	10
2.3.1	Espaces de Hilbert à noyaux reproduisants	11
2.3.2	Définition du HSIC via la MMD	11
2.3.3	Estimateurs empiriques	12
2.3.4	Tests sur le HSIC	14
2.4	Comparaison numérique entre Sobol et HSIC	15
2.4.1	Sur la G-fonction (indépendance des entrées)	15
2.4.2	Sur la fonction de Friedman (indépendance des entrées, interactions) . . .	19
2.4.3	Sur la fonction de Friedman (dépendance des entrées et interaction) . . .	21
2.4.4	Sur un cas d'exemple : MARTHE	22
2.5	Synthèse	26
3	Analyse de sensibilité dans un système multi-niveaux	28
3.1	Systèmes feed-forward	28
3.2	Modélisation de la dépendance	28
3.2.1	Théorie des copules	29
3.2.2	Mesures de concordance	30
3.3	Méthode développée	31
3.4	Validation sur un exemple analytique	37
3.5	Sur un système en cascade	43
4	Conclusion	49
4.1	Apports du stage	49
4.2	Pistes d'amélioration	50
5	Annexes	52
5.1	HSIC-ANOVA	52
5.1.1	Noyaux ANOVA	52
5.1.2	Noyau de Sobolev	52
5.1.3	Décomposition HSIC-ANOVA	53
5.1.4	Indices associés	53
5.2	HSIC-Shapley	54
5.2.1	Rappel sur la MMD	54
5.2.2	Définition des indices	54
5.3	Suite du cas du dataset MARTHE	54
5.3.1	HSIC-ANOVA	54

5.3.2	HSIC-Shapley	57
-------	------------------------	----

1 Introduction

Beaucoup de problèmes industriels reposent sur la simulation de systèmes complexes faisant intervenir plusieurs phénomènes physiques. Ces systèmes sont souvent multidisciplinaires : le contrôle d'un satellite par exemple nécessite de gérer le couplage, l'apport en énergie et l'altitude d'orbite. Ces 3 domaines dépendant de plusieurs variables et sont décrites en une multitude d'équations.

Un problème comme celui-ci a donc plusieurs problèmes qui doivent être gérés : le coût de calcul pour chaque évaluation du modèle peut être élevé, ce qui limite les données. Ensuite, les interactions entre les différentes disciplines peuvent rendre difficile l'identification des mécanismes responsables de la variabilité des sorties. Enfin, lorsque le modèle est utilisé comme une boîte noire, il peut être difficile de comprendre le rôle respectif des paramètres d'entrée et des paramètres intermédiaires inter-disciplines et de déterminer quels phénomènes contribuent réellement à la réponse.

L'analyse de sensibilité permet de répondre à ces problèmes, son but étant de retrouver les variables qui expliquent le mieux l'incertitude/ la variabilité d'un système. Deux manières classiques sont distinguées en AS. Le *ranking* et le *screening*. Le *screening* consiste à trouver les variables qui ne sont pas influentes sur la sortie, afin de soit les enlever soit de les fixer à des valeurs nominales. Le *ranking*, quant à lui, cherche à trouver un classement des variables les plus influentes sur la sortie. Trouver les variables les plus influentes peut servir à optimiser sur un espace de dimension réduit par exemple, et d'autant plus réduit qu'on a pu enlever de variables non influentes via un *screening*. Ceci peut déjà permettre de réduire le coût numérique et rendre le système un peu plus interprétable. Il y a aussi une autre séparation dans l'AS : l'analyse de sensibilité *global* et l'analyse de sensibilité *locale*. L'analyse de sensibilité locale mesure l'effet de petites variations d'une variable autour d'une valeur donnée, tandis que l'analyse globale étudie l'influence des variables sur l'ensemble de leurs plages de variation, y compris leurs interactions.

Le contexte de ce stage est celui de l'analyse de sensibilité appliquée à des systèmes multidisciplinaires de type *feed-forward*. Un système *feed-forward* est un système dans lequel l'information circule dans une seule direction, depuis les entrées vers les sorties, sans boucle de rétroaction. Les sorties d'un niveau donné peuvent donc être utilisées comme entrées d'un niveau suivant, mais elles ne retournent pas vers un niveau précédent. La structure du système peut ainsi être représentée par un graphe orienté acyclique, comme l'illustre la figure 1.




FIGURE 1 – Exemple de système feed-forward.

De manière intuitive, la structure feed-forward peut être résumée par une succession de flèches

orientées vers l'avant, sans retour vers les niveaux précédents. Cette propriété permet d'étudier simplement la propagation de l'influence des variables à travers les différents niveaux du système. L'objectif de ce stage est justement d'exploiter cette structure pour analyser la sensibilité d'un système feed-forward à plusieurs niveaux.

Dans un premier temps, nous nous intéressons à la mise en œuvre de l'analyse de sensibilité globale dans le cadre d'un système simple de la forme ($Y = f(X)$). Nous présentons tout d'abord brièvement les principales méthodes de *screening*, qui permettent d'identifier les paramètres les plus influents. Nous introduisons ensuite les indices de Sobol, qui constituent une méthode de référence en analyse de sensibilité globale fondée sur la décomposition de la variance. Enfin, nous étudions d'autres mesures de sensibilité, notamment les indices de Sobol-Shapley et le critère HSIC (Hilbert-Schmidt Independence Criterion), dont les propriétés et les résultats seront analysés et comparés à ceux obtenus avec les indices de Sobol.

Dans un second temps, nous présentons la méthode développée afin d'étendre l'analyse de sensibilité à des systèmes de type feed-forward. Les différentes étapes de cette approche sont décrites en détail, puis la méthode est validée par comparaison avec une approche proposée dans la littérature. Enfin, nous l'appliquons à un système feed-forward organisé en cascade afin d'étudier la propagation de l'information au sein du système et d'évaluer la capacité de la méthode à caractériser correctement les mécanismes de transmission de l'influence entre les différentes composantes.

2 Analyse de sensibilité globale d'un système entrée-sortie simple

Dans cette première partie, on considère un cadre classique d'analyse de sensibilité globale, dans lequel les variables d'entrée sont transformées par une fonction unique afin de produire la sortie du système.



FIGURE 2 – Boîte noire : entrées $X_1, \dots, X_d$ et sortie scalaire $Y = f(X)$.

L'objectif est d'étudier l'influence des différentes entrées sur la sortie à l'aide de méthodes de screening et de ranking.

2.1 Sous l'hypothèse d'indépendance des entrées

Dans la suite, sauf mention du contraire, nous supposons que les variables d'entrée $(X_i)_{1 \leq i \leq d}$ sont mutuellement indépendantes. Cette hypothèse correspond au cadre classique couramment considéré en analyse de sensibilité globale.

2.1.1 Méthode de Morris

La méthode de Morris, développée par Morris, s'inscrit dans la famille des plans OAT (*One At a Time*), où l'on fait varier une seule variable à la fois en gardant les autres fixées. Il existe d'autres plans que les plans OAT, qui sont notamment cités dans [9]. Cette méthode de Morris est une méthode de **screening** : elle sert à identifier rapidement les variables négligeables, puis celles qui semblent linéaires ou au contraire fortement non linéaires.

La méthode de Morris vise à classer les variables en trois groupes :

- Variables négligeables.
- Variables à effet linéaire significatif sans interactions.
- Variables à effet non linéaire significatif et/ou à effets d'interaction.

Pour cela, on calcule des effets élémentaires. Pour la variable i , l'effet élémentaire associé à la j -ème répétition du plan est défini par

$$E_i^{(j)} = \frac{f(X^{(j)} + \Delta e_i) - f(X^{(j)})}{\Delta}, \quad (1)$$

où e_i est le i -ème vecteur de la base canonique, Δ un multiple de $\frac{1}{n-1}$, et j l'indice de répétition du design OAT.

On calcule ensuite ces effets sur r trajectoires OAT, puis on résume l'information par deux quantités :

$$\mu_i = \frac{1}{r} \sum_{j=1}^r |E_i^{(j)}| \quad (2)$$

et

$$\sigma_i = \sqrt{\frac{1}{r} \sum_{j=1}^r \left(E_i^{(j)} - \frac{1}{r} \sum_{j=1}^r E_i^{(j)} \right)^2}. \quad (3)$$

Ici, μ_i est la moyenne des valeurs absolues des effets élémentaires, et σ_i leur écart-type. L'interprétation est simple : plus μ_i est grand, plus la variable i est influent, et plus σ_i est grand, moins son effet est celui d'un comportement linéaire. Un exemple d'interprétation est donné dans [9].

En résumé, Morris est une méthode très naturelle de screening, en particulier lorsqu'on veut réduire la dimension du problème avant d'appliquer des méthodes plus coûteuses.

2.1.2 DGSM

Les DGSM (*Derivative based Global Sensitivity Measures*), comme expliqué dans [19], peuvent être vus comme une moyenne globale des variations locales. À la différence de Morris, ils reposent sur les dérivées partielles de la fonction. L'idée est donc de passer d'une quantité locale, la dérivée, à une mesure globale en la moyennant. On écrit l'indice DGSM sous la forme

$$\nu_i = \int \left(\frac{\partial f(y)}{\partial x_i} \right)^2 dy. \quad (4)$$

D'autres variantes existent, par exemple en ajoutant un poids en x^m dans l'intégrande. Comme Morris, les DGSM sont essentiellement des outils de **screening**. Ils permettent de repérer les variables dont une petite perturbation entraîne un changement important sur la sortie. En pratique, un simple barplot des ν_i permet déjà de faire un premier tri des variables influentes. Les DGSM ont aussi l'avantage d'être plus simples à interpréter que Morris : plus l'indice est haut, plus la perturbation de la variable influe sur la sortie. Ils constituent donc une très bonne méthode de présélection avant le ranking. Cependant il faut toujours que l'intégrale existe et qu'on ait la fonction modèle pour pouvoir passer par des différences finies ou par une dérivée d'un métamodèle.

2.1.3 Décomposition de Hoeffding

Au-delà de l'identification des variables influentes, l'analyse de sensibilité vise également à quantifier et à comparer leur importance relative, afin d'établir un classement des contributions des différentes entrées à la variabilité de la sortie. Dans ce cadre, un résultat fondamental est la décomposition de Hoeffding, qui constitue notamment le fondement de la décomposition ANOVA fonctionnelle et des indices de Sobol, ces derniers figurant parmi les mesures de référence en analyse de sensibilité globale.

Soit $f : [0, 1]^d \rightarrow \mathbb{R}$ une fonction de carré intégrable. La décomposition de Hoeffding (1948) s'écrit :

$$f(X_1, \dots, X_d) = f_0 + \sum_{i=1}^d f_i(X_i) + \sum_{i < j} f_{ij}(X_i, X_j) + \dots + f_{1\dots d}(X_1, \dots, X_d), \quad (5)$$

où les composantes sont définies récursivement par

$$f_0 = \mathbb{E}[Y], \quad (6)$$

$$f_i(X_i) = \mathbb{E}[Y \mid X_i] - f_0, \quad (7)$$

$$f_{ij}(X_i, X_j) = \mathbb{E}[Y \mid X_i, X_j] - f_i - f_j - f_0, \quad (8)$$

$$\vdots \quad (9)$$

La décomposition est unique sous la condition d'intégrale nulle pour chaque composante :

$$\int f_u(X_u) dX_k = 0 \quad \text{pour tout } u \subseteq \{1, \dots, p\}, \quad k \in u. \quad (10)$$

Cette condition garantit l'orthogonalité des composantes dans L^2 :

$$\int f_u(X_u) f_v(X_v) dX = 0 \quad \text{pour } u \neq v. \quad (11)$$

Sous l'hypothèse d'indépendance des entrées, Sobol montre que la variance totale de Y se décompose comme une somme de contributions propres et d'interactions :

$$\text{Var}(Y) = \sum_i V_i + \sum_{i < j} V_{ij} + \dots + V_{1\dots d}, \quad (12)$$

avec

$$V_i = \text{Var}(\mathbb{E}[Y \mid X_i]), \quad (13)$$

$$V_{ij} = \text{Var}(\mathbb{E}[Y \mid X_i, X_j]) - V_i - V_j. \quad (14)$$

Cette décomposition est vraie sous l'hypothèse que les variables $X_1, \dots, X_d$ sont indépendantes.

2.1.4 Indices de Sobol

À partir de cette décomposition, plusieurs indices de sensibilité peuvent être définis, chacun permettant de caractériser différentes contributions des variables d'entrée à la variabilité de la sortie :

- **Indice du premier ordre** mesure la part de variance expliquée par X_i seul

$$S_i = \frac{V_i}{\text{Var}(Y)}, \quad (15)$$

- **Indice total** mesure l'effet global de X_i , interactions comprises

$$S_{T_i} = 1 - \frac{\text{Var}(\mathbb{E}[Y \mid X_{-i}])}{\text{Var}(Y)}, \quad (16)$$

- **Indice fermé** associé à un groupe u

$$S_u^{\text{ferm}} = \frac{\text{Var}(\mathbb{E}[Y \mid X_u])}{\text{Var}(Y)}. \quad (17)$$

Les indices de Sobol sont donc premièrement des outils de **ranking**, même si en pratique on peut aussi faire du screening avec les variables à indice proche de 0. Ils permettent de classer les variables selon leur contribution à la variance de sortie, tout en distinguant les effets principaux et les effets d'interaction. La différence $S_{T_i} - S_i$ quantifie précisément la part d'interaction de X_i avec les autres variables.

Prenons un exemple numérique simple. Considérons le modèle

$$Y = X_1 + X_2 + X_1 X_2, \quad (18)$$

avec $X_1, X_2, X_3 \sim \mathcal{U}(-1, 1)$. La variance totale vaut

$$\text{Var}(Y) = \frac{7}{9}, \quad (19)$$

avec la décomposition

$$\text{Var}(Y) = V_1 + V_2 + V_{12} = \frac{1}{3} + \frac{1}{3} + \frac{1}{9}. \quad (20)$$

Les indices de Sobol sont alors :

Variable	S_i	S_{T_i}	$S_{T_i} - S_i$
X_1	$\frac{3}{7}$	$\frac{4}{7}$	$\frac{1}{7}$
X_2	$\frac{3}{7}$	$\frac{4}{7}$	$\frac{1}{7}$
X_3	0	0	0

On vérifie bien que $S_1 + S_2 + S_{12} = 1$. Cette petite expérience montre que Sobol permet bien de faire du ranking dans un cadre indépendant.

2.1.5 Méthode Pick-Freeze

Dans le cas considéré ici, la simplicité du modèle peut masquer le coût numérique associé à l'estimation des indices de Sobol. En pratique, leur calcul nécessite généralement un nombre de simulations élevé, notamment en raison du schéma d'estimation utilisé. On considère ici l'estimateur de type Pick-Freeze. On s'intéresse à la quantité :

$$V_u = \mathbb{E} \left[(\mathbb{E}[Y | X_u])^2 \right] - (\mathbb{E}[Y])^2, \quad (21)$$

et on construit un plan d'expériences $((X^{(j,u)}; \tilde{X}^{(j,-u)}))_{j=1}^N$ tel que

$$\left(X^{(j,u)}; \tilde{X}^{(j,-u)} \right)_i = \begin{cases} x_{j,i} & \text{si } i \in u, \\ \tilde{x}_{j,i} & \text{si } i \notin u. \end{cases} \quad (22)$$

L'estimateur Pick-Freeze de V_u est alors

$$\hat{V}_u = \frac{1}{N} \sum_{j=1}^N f\left(X^{(j,u)}; \tilde{X}^{(j,-u)}\right) f\left(X^{(j)}\right) - \left(\frac{1}{N} \sum_{j=1}^N f\left(X^{(j)}\right) \right)^2, \quad (23)$$

et l'indice estimé est $\hat{S}_u = \hat{V}_u / \widehat{\text{Var}}(Y)$. En pratique, on peut utiliser le package `sensitivity` de R, qui implémente plusieurs estimateurs des indices de Sobol.

Malgré leur large utilisation, les indices de Sobol présentent certaines limitations :

- leur estimation peut entraîner un coût de calcul important, notamment en raison du schéma de type *Pick-Freeze*, qui nécessite la génération de plusieurs jeux d'échantillons ;
- leur formulation classique repose sur l'hypothèse d'indépendance des variables d'entrée.

Afin de dépasser ces limitations et d'étendre le cadre d'application des indices de Sobol, plusieurs approches alternatives ou complémentaires ont été proposées dans la littérature.

2.2 Sous dépendance

Nous nous intéressons tout d'abord à l'extension des indices de Sobol au cas où les variables d'entrée présentent des dépendances. Une manière d'aborder cette problématique consiste à utiliser des outils issus de la théorie des jeux, et en particulier les valeurs de Shapley.

Remarque 1. *On tient à noter que les indices de Sobol fermés permettent d'évaluer l'influence conjointe de groupes de variables. Une première approche pour traiter les dépendances entre entrées consiste à regrouper les variables dépendantes, puis à calculer les indices de sensibilité au niveau de ces groupes. Cette stratégie sera utilisée plus loin dans le rapport dans le cadre des indices HSIC.*

2.2.1 Éléments de théorie des jeux

Avant d'introduire les indices de Sobol-Shapley, il faut définir le cadre de la théorie des jeux. On considère d joueurs, réunis dans l'ensemble

$$[d] := \{1, \dots, d\}.$$

Chaque sous-ensemble $u \subseteq [d]$ représente une coalition possible. On note $\mathcal{P}_d$ l'ensemble des parties de $[d]$, qui en contient 2^d . Le bilan économique du jeu est décrit par une fonction caractéristique

$$c_0 : \mathcal{P}_d \rightarrow \mathbb{R}_+, \quad u \mapsto c_0(u),$$

avec $c_0(\emptyset) = 0$. Shapley introduit ensuite les valeurs de Shapley s_j , fondées sur quatre axiomes :

(S1) Partage de la totalité des gains.

$$\sum_{j=1}^d s_j(c_0) = c_0([d]).$$

(S2) Symétrie de la répartition des gains.

Si, pour tous $S \subseteq [d] \setminus \{i, j\}$, $c(S \cup \{i\}) = c(S \cup \{j\})$, alors $s_i(c) = s_j(c)$.

(S3) Non-rétribution des collaborations infructueuses.

Si, pour tout $S \subseteq [d] \setminus \{j\}$, $c(S \cup \{i\}) = c(S)$, alors $s_i(c) = 0$.

(S4) Linéarité par rapport à la fonction caractéristique.

$$s_j(c_1 + c_2) = s_j(c_1) + s_j(c_2).$$

Ces axiomes caractérisent de façon unique les valeurs de Shapley. Cela permet ensuite d'utiliser une fonction caractéristique construite à partir d'une mesure de sensibilité, par exemple la variance conditionnelle, pour obtenir les indices de Sobol-Shapley.

2.2.2 Indices de Sobol-Shapley

Si on définit comme fonction caractéristique la variance conditionnelle,

$$\forall u \subseteq [d], \quad c_{\text{Sb}}(u) = \frac{\mathbb{V}[\mathbb{E}[Y \mid X_u]]}{\mathbb{V}(Y)} = S_u^{\text{ferm}}. \quad (24)$$

On se retrouve alors exactement dans le cadre du théorème de Shapley. L'indice Sobol-Shapley associée à la j -ème entrée est donc

$$\forall 1 \leq j \leq d, \quad \phi_j := \frac{1}{d} \sum_{i \notin u} \frac{1}{\binom{|u|}{d-1}} \left(S_{u \cup \{i\}}^{\text{ferm}} - S_u^{\text{ferm}} \right). \quad (25)$$

De plus, il est montré dans [14] qu'en repartant de la décomposition ANOVA, on a

$$\forall 1 \leq i \leq d, \quad \phi_i = \frac{1}{\sigma^2} \sum_{u \ni i} \frac{\sigma_u^2}{|u|}, \quad \text{et donc} \quad S_i^{\text{ferm}} \leq \phi_i \leq S_{T_i}.$$

Les indices de Sobol-Shapley présentent donc deux propriétés remarquables. D'une part, comme $c_{\text{Sb}}(\emptyset) = 0$ et $c_{\text{Sb}}([d]) = 1$, la somme des valeurs de Shapley vaut 1 : la variance de sortie est entièrement répartie entre les entrées, ce qui n'est pas le cas des Sobol classiques avec des variables dépendantes. D'autre part, l'encadrement précédent fait apparaître ϕ_i comme un compromis naturel entre l'effet principal S_i^{ferm} et l'indice total S_{T_i} .

On peut aussi étendre la logique de Shapley à d'autres mesures de sensibilité. Il y a par exemple l'extension aux indices de Borgonovo, proposée dans [17], en remplaçant la fonction caractéristique par une mesure basée sur $\delta_{Y|X_u}$, ce qui conserve la propriété de somme à 1.

2.2.3 Estimation par permutations

On voit à la tête de nos indices que si on y va naïvement, il va falloir calculer 2^d indices. Il faut donc contourner ce problème. [1] proposent une réécriture par permutations de ces indices. En notant $\mathfrak{P}_d$ l'ensemble des $d!$ permutations de $[d]$ et $P_i(\pi)$ l'ensemble des variables qui apparaissent avant i dans la permutation π , on a

$$\phi_i = \mathbb{E}_{\Pi \sim \mathcal{U}(\mathfrak{P}_d)} [c_0(P_i(\Pi) \cup \{i\}) - c_0(P_i(\Pi))],$$

ce qui est valable quelle que soit la fonction caractéristique c_0 . Cette réécriture est le point de départ de l'estimateur Monte-Carlo de Song [20] : on tire m permutations $\pi_1, \dots, \pi_m$ indépendamment et uniformément dans $\mathfrak{P}_d$, et on approche l'espérance par la moyenne empirique

$$\widehat{\text{Sh}}_i = \frac{1}{m} \sum_{r=1}^m [c_0(P_i(\pi_r) \cup \{l\}) - c_0(P_i(\pi_r))].$$

Chaque permutation π_r fait intervenir exactement d coalitions distinctes - une par position dans π_r - et les m permutations partagent leurs coalitions entre les d variables simultanément. Le coût total est donc de $m \times d$ évaluations de c_0 , contre $2^d - 1$ pour le calcul exact.

Song et al. [20] montrent de plus que cet estimateur est sans biais et que son erreur quadratique moyenne décroît en $\mathcal{O}(1/m)$, indépendamment de d . En pratique, $m = 100$ à 200 permutations suffisent pour obtenir une précision satisfaisante.

2.2.4 Distance covariance et distance corrélation

D'autres indices ont été aussi créés, comme par exemple l'indice de Borgonovo sus-cité, ou des indices découlant de mesures de dépendance que l'on peut retrouver dans un article de [9]. Cependant ces méthodes peuvent souffrir de plusieurs défauts, comme notamment le fléau de la dimension à cause des estimations à noyau. Pour contourner ces difficultés liées aux estimations à noyau, Székely introduit la distance covariance. On pose donc la distance covariance comme suit :

$$\mathcal{V}^2(X, Y) = \int_{\mathbb{R}^{p+q}} \frac{|\varphi_{X,Y}(t, s) - \varphi_X(t)\varphi_Y(s)|^2}{c_p c_q \|t\|^{p+1} \|s\|^{q+1}} dt ds,$$

où

$$w(t, s) = (c_p c_q \|t\|^{1+p} \|s\|^{1+q})^{-1},$$

avec, pour tout entier $k \geq 1$,

$$c_k = \frac{\pi^{(1+k)/2}}{\Gamma((1+k)/2)}.$$

La distance corrélation est alors définie par

$$\mathcal{R}^2(X, Y) = \frac{\mathcal{V}^2(X, Y)}{\sqrt{\mathcal{V}^2(X, X)\mathcal{V}^2(Y, Y)}}. \quad (26)$$

Elle vérifie $0 \leq \mathcal{R}(X, Y) \leq 1$, avec $\mathcal{R}(X, Y) = 0 \iff X \perp Y$ quelle que soit la dimension. Elle détecte donc les dépendances linéaires et non linéaires. Les estimateurs empiriques de Székely sont

$$\mathcal{V}_n^2(X, Y) = \frac{1}{n(n-1)} \sum_{k,l=1}^n \|X_k - X_l\| \|Y_k - Y_l\|, \quad (27)$$

$$\mathcal{R}_n^2(X, Y) = \frac{\mathcal{V}_n^2(X, Y)}{\sqrt{\mathcal{V}_n^2(X, X)\mathcal{V}_n^2(Y, Y)}}. \quad (28)$$

L'avantage majeur est qu'aucune estimation à noyau n'est nécessaire : tout est calculable directement, même si le coût peut rester élevé. Là encore, on est dans une logique de ranking.

2.3 Hilbert-Schmidt Independence Criterion (HSIC)

Le critère HSIC (*Hilbert-Schmidt Independence Criterion*), introduit par [8], s'inscrit dans la même famille que la distance covariance, mais dans le cadre plus général des espaces de Hilbert à noyaux reproduisants (*Reproducing Kernel Hilbert Spaces*, RKHS). Il présente un nouvel avantage non-négligeable : on peut créer des tests d'indépendance avec celui-ci.

2.3.1 Espaces de Hilbert à noyaux reproduisants

Définition 1 (Espace de Hilbert). *Un espace de Hilbert $\mathcal{H}$ est un espace vectoriel réel muni d'un produit scalaire $\langle \cdot, \cdot \rangle_{\mathcal{H}}$, complet pour la norme induite $\|f\|_{\mathcal{H}} = \sqrt{\langle f, f \rangle_{\mathcal{H}}}$.*

Définition 2 (Noyau reproduisant et RKHS). *Soit $\mathcal{X}$ un ensemble non vide. Une fonction symétrique définie positive $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ est dite noyau reproduisant d'un espace de Hilbert $\mathcal{H}$ de fonctions $\mathcal{X} \rightarrow \mathbb{R}$ si :*

1. pour tout $x \in \mathcal{X}$, $k(\cdot, x) \in \mathcal{H}$;
2. pour tout $f \in \mathcal{H}$ et tout $x \in \mathcal{X}$, $f(x) = \langle f, k(\cdot, x) \rangle_{\mathcal{H}}$ (propriété reproduisante).

Un tel espace $\mathcal{H}$ est appelé espace de Hilbert à noyau reproduisant (RKHS).

La feature map canonique associée à k est

$$\phi : \mathcal{X} \rightarrow \mathcal{H}, \quad \phi(x) = k(\cdot, x),$$

de sorte que $k(x, x') = \langle \phi(x), \phi(x') \rangle_{\mathcal{H}}$.

On voit donc que le HSIC va être sensible au noyau choisi. Il faut donc qu'il ait des propriétés suffisantes pour qu'on puisse faire des statistiques avec.

Théorème 1 (Mercer). *Tout noyau symétrique défini positif définit un RKHS unique, et réciproquement tout RKHS admet un noyau reproduisant unique.*

Définition 3 (Noyau universel). *Soit $\mathcal{X}$ un espace compact. Un noyau continu $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ est dit universel si le RKHS associé $\mathcal{H}_k$ est dense dans $\mathcal{C}(\mathcal{X})$ pour la norme uniforme, c'est-à-dire :*

$$\forall f \in \mathcal{C}(\mathcal{X}), \forall \varepsilon > 0, \exists g \in \mathcal{H}_k : \|f - g\|_{\infty} < \varepsilon.$$

Définition 4 (Plongement de moyenne et noyau caractéristique). *Soit $\mathcal{P}$ l'ensemble des mesures de probabilité sur $\mathcal{X}$. Pour $P \in \mathcal{P}$, le plongement de moyenne associé au noyau k est l'élément de $\mathcal{H}_k$ défini par*

$$\mu_P := \mathbb{E}_{X \sim P}[k(\cdot, X)] = \int_{\mathcal{X}} k(\cdot, x) dP(x).$$

Le noyau k est dit caractéristique si l'application $P \mapsto \mu_P$ est injective, c'est-à-dire :

$$\mu_P = \mu_Q \implies P = Q.$$

Proposition 1. *Tout noyau universel est caractéristique. En particulier, le noyau gaussien (auss appelé RBF) $k(x, x') = \exp(-\|x - x'\|^2/2\sigma^2)$, le noyau de Laplace et les noyaux de Matérn 3/2 et 5/2 sont caractéristiques sur tout compact.*

2.3.2 Définition du HSIC via la MMD

La *Maximum Mean Discrepancy* (MMD) fournit le cadre naturel pour définir le HSIC. Soient $\mathcal{H}_X$ et $\mathcal{H}_Y$ deux RKHS de noyaux k_X et k_Y sur $\mathcal{X}$ et $\mathcal{Y}$ respectivement. Notons P_{XY} la loi jointe de (X, Y) et $P_X \otimes P_Y$ le produit des lois marginales.

Définition 5 (MMD). *La Maximum Mean Discrepancy entre deux distributions P et Q dans un RKHS $\mathcal{H}_k$ est définie par*

$$\text{MMD}(P, Q) = \sup_{\|f\|_{\mathcal{H}_k} \leq 1} |\mathbb{E}_{X \sim P}[f(X)] - \mathbb{E}_{X \sim Q}[f(X)]| = \|\mu_P - \mu_Q\|_{\mathcal{H}_k}.$$

Si k est caractéristique, alors $\text{MMD}(P, Q) = 0 \Leftrightarrow P = Q$.

En fait, le HSIC mesure la dépendance entre X et Y en quantifiant l'écart entre P_{XY} et $P_X \otimes P_Y$ dans l'espace de plongement via un opérateur particulier :

Définition 6 (Opérateur de covariance croisée). *L'opérateur de covariance croisée $C_{XY} : \mathcal{H}_Y \rightarrow \mathcal{H}_X$ est défini par*

$$C_{XY} = \mathbb{E}_{XY}[\phi(X) \otimes \psi(Y)] - \mathbb{E}_X[\phi(X)] \otimes \mathbb{E}_Y[\psi(Y)],$$

où $\phi(x) = k_X(\cdot, x)$ et $\psi(y) = k_Y(\cdot, y)$ sont les feature maps canoniques. Pour tout $f \in \mathcal{H}_X$ et $g \in \mathcal{H}_Y$, on a

$$\langle f, C_{XY} g \rangle_{\mathcal{H}_X} = \mathbb{E}_{XY}[f(X)g(Y)] - \mathbb{E}_X[f(X)] \mathbb{E}_Y[g(Y)].$$

Définition 7 (HSIC). *Le critère HSIC est défini comme le carré de la norme de Hilbert-Schmidt de l'opérateur de covariance croisée :*

$$\text{HSIC}(X, Y)_{\mathcal{H}_X, \mathcal{H}_Y} = \|C_{XY}\|_{\text{HS}}^2 = \text{MMD}^2(P_{XY}, P_X \otimes P_Y).$$

Proposition 2 ([8]). *Le HSIC admet l'expression analytique suivante, en notant (X', Y') une copie indépendante de (X, Y) :*

$$\begin{aligned} \text{HSIC}(X, Y) &= \mathbb{E}[k_X(X, X') k_Y(Y, Y')] \\ &\quad + \mathbb{E}[k_X(X, X')] \mathbb{E}[k_Y(Y, Y')] \\ &\quad - 2 \mathbb{E}[\mathbb{E}_{X'}[k_X(X, X')] \mathbb{E}_{Y'}[k_Y(Y, Y')]]. \end{aligned} \quad (29)$$

Remarque 2. *Il faut noter que pour ce résultat théorique, on introduit la copie indépendante de l'échantillon uniquement pour pouvoir écrire proprement le HSIC sous forme d'espérance. C'est en réalité une égalité sur les lois derrière.*

Indice de sensibilité normalisé. Par analogie avec la distance corrélation, on définit aussi l'indice HSIC normalisé :

$$S^{\text{HSIC}} = R^2(X, Y) = \frac{\text{HSIC}(X, Y)}{\sqrt{\text{HSIC}(X, X) \text{HSIC}(Y, Y)}}.$$

Cet indice appartient à $[0, 1]$ et vaut 0 si et seulement si $X \perp Y$ (pour un noyau caractéristique). Il fournit un outil naturel de screening via les tests, y compris pour des sorties fonctionnelles ou multivariées. Mais contrairement aux indices de Sobol, il n'admet pas d'interprétation directe en termes de partage de variance.

2.3.3 Estimateurs empiriques

En pratique lors de l'estimation, on aura seulement à utiliser un autre tirage du même échantillon. Lorsque nous utiliserons `sensiHSIC` du package `sensitivity`, ce qu'on aura comme estimation est en fait ceci :

$$\begin{aligned} \widehat{\text{HSIC}}_V(X, Y) &= \frac{1}{n^2} \sum_{i,j=1}^n k(X^{(i)}, X^{(j)}) \ell(Y^{(i)}, Y^{(j)}) \\ &\quad + \frac{1}{n^4} \left(\sum_{i,j=1}^n k(X^{(i)}, X^{(j)}) \right) \left(\sum_{i,j=1}^n \ell(Y^{(i)}, Y^{(j)}) \right) \\ &\quad - \frac{2}{n^3} \sum_{i,j=1}^n \left(\sum_{r=1}^n k(X^{(i)}, X^{(r)}) \right) \left(\sum_{s=1}^n \ell(Y^{(j)}, Y^{(s)}) \right). \end{aligned}$$

Nous allons voir, juste après le résultat suivant, les estimateurs V-stat et U-stat du HSIC plus en détail. Quand il s'agira d'estimer le $R^2 - \text{HSIC}$, on utilisera l'estimateur V-statistique pour les trois termes, car elle est positive même pour les petits n , contrairement à la U-stat : $\widehat{R}^2 \in [0, 1]$:

$$\widehat{S}_k^{\text{HSIC}} = \widehat{R}^2(X_k, Y) = \frac{\widehat{\text{HSIC}}_V(X_k, Y)}{\sqrt{\widehat{\text{HSIC}}_V(X_k, X_k) \widehat{\text{HSIC}}_V(Y, Y)}},$$

Proposition 3. Si k_X et k_Y sont caractéristiques, alors

$$\text{HSIC}(X, Y) = 0 \iff X \perp Y.$$

Le HSIC peut donc clairement nous permettre de faire du screening grâce à cette proposition, à condition de bien choisir les noyaux. Soit $\{(X^{(i)}, Y^{(i)})\}_{i=1}^n$ un échantillon i.i.d. de loi P_{XY} . On note K et L les matrices de Gram de taille $n \times n$ définies par $K_{ij} = k_X(X^{(i)}, X^{(j)})$ et $L_{ij} = k_Y(Y^{(i)}, Y^{(j)})$.

Proposition 4. L'estimateur V -statistique s'écrit de façon compacte :

$$\widehat{\text{HSIC}}_V(X, Y) = \frac{1}{n^2} \text{tr}(K_c L_c),$$

où $K_c = HKH$, $L_c = H LH$, et $H = I_n - \frac{1}{n} \mathbf{1}\mathbf{1}^\top$ est la matrice de centrage.

Démonstration. On développe $\text{tr}(K_c L_c) = \text{tr}(HKH LH) = \text{tr}(KL) - \frac{1}{n} \text{tr}(\mathbf{1}^\top KL \mathbf{1}) - \frac{1}{n} \text{tr}(K \mathbf{1}\mathbf{1}^\top L) + \frac{1}{n^2} \text{tr}(\mathbf{1}^\top K \mathbf{1}\mathbf{1}^\top L \mathbf{1})$.

$$\begin{aligned} \text{tr}(K_c L_c) &= \text{tr}(KL) - \frac{1}{n} \text{tr}(\mathbf{1}^\top KL \mathbf{1}) - \frac{1}{n} \text{tr}(K \mathbf{1}\mathbf{1}^\top L) + \frac{1}{n^2} \text{tr}(\mathbf{1}^\top K \mathbf{1}\mathbf{1}^\top L \mathbf{1}) \\ &= \sum_{i,j} K_{ij} L_{ij} - \frac{1}{n} \sum_{i,j} \left(\sum_r K_{ir} \right) \left(\sum_s L_{sj} \right) - \frac{1}{n} \sum_{ij} \left(\sum_i K_{ir} \right) \left(\sum_i L_{sj} \right) \\ &\quad + \frac{1}{n^2} \left(\sum_{i,j} K_{ij} \right) \left(\sum_{i,j} L_{ij} \right). \end{aligned}$$

En divisant par n^2 on retrouve exactement la définition de $\widehat{\text{HSIC}}_V$. □

Remarque 3. L'estimateur V -statistique est biaisé : $\mathbb{E}[\widehat{\text{HSIC}}_V] = \text{HSIC}(X, Y) + O(n^{-1})$. Il est en revanche toujours non négatif et de complexité $\mathcal{O}(n^2)$.

Définition 8 (Estimateur U -statistique). Soient $\tilde{K}$ et $\tilde{L}$ les matrices de Gram dont les termes diagonaux sont mis à zéro :

$$\tilde{K}_{ij} = K_{ij}(1 - \delta_{ij}), \quad \tilde{L}_{ij} = L_{ij}(1 - \delta_{ij}).$$

L'estimateur U -statistique du HSIC est défini par

$$\widehat{\text{HSIC}}_U(X, Y) = \frac{1}{n(n-3)} \left[\text{tr}(\tilde{K} \tilde{L}) + \frac{\mathbf{1}^\top \tilde{K} \mathbf{1} \mathbf{1}^\top \tilde{L} \mathbf{1}}{(n-1)(n-2)} - \frac{2}{n-2} \mathbf{1}^\top \tilde{K} \tilde{L} \mathbf{1} \right].$$

Proposition 5. $\widehat{\text{HSIC}}_U$ est un estimateur sans biais du HSIC :

$$\mathbb{E}[\widehat{\text{HSIC}}_U(X, Y)] = \text{HSIC}(X, Y).$$

Remarque 4. Les deux estimateurs sont asymptotiquement équivalents :

$$\widehat{\text{HSIC}}_V = \frac{(n-1)^2}{n^2} \widehat{\text{HSIC}}_U + O(n^{-2}).$$

En pratique, $\widehat{\text{HSIC}}_V$ est préféré pour les tests d'indépendance car forcément non-négative et pour le calcul des indices HSIC-ANOVA, alors que $\widehat{\text{HSIC}}_U$ est préféré lorsque l'absence de biais est importante par exemple pour un petit échantillon. Sa complexité est $\mathcal{O}(n^2)$ dans les deux cas.

2.3.4 Tests sur le HSIC

On va appuyer sur le fait que les HSIC, même s'ils sont construits dans la suite d'un paradigme d'indices de rankings, vont plutôt servir pour le screening. Comme on a dit préalablement, on ne sait pas ce qui est vraiment mesuré, le ranking peut paraître très particulier. Un exemple est le ranking obtenu par HSIC sur la célèbre fonction d'Ishigami, comme on peut le voir dans le comparatif des différents indices de sensibilité fait par [2], qui est complètement différent du ranking obtenu par les autres types d'indice de sensibilité. C'est pourquoi on va plutôt se pencher sur le HSIC pour faire des tests. Ces tests ont été développés par [8].

On a vu précédemment qu'un HSIC nul équivaut à une indépendance. On peut donc reformuler le test d'indépendance, qui teste initialement :

$$H_0 : \mathbb{P}_{X_i Y} = \mathbb{P}_{X_i} \otimes \mathbb{P}_Y \quad \text{vs} \quad H_1 : \mathbb{P}_{X_i Y} \neq \mathbb{P}_{X_i} \otimes \mathbb{P}_Y,$$

en un test équivalent portant directement sur la statistique HSIC :

$$H_0 : \text{HSIC}(X_i, Y) = 0 \quad \text{vs} \quad H_1 : \text{HSIC}(X_i, Y) > 0.$$

Voyons maintenant comment le faire en pratique.

Test asymptotique. On a déjà cité les théorèmes nécessaires montrés par [8], on peut donc maintenant montrer la procédure du test asymptotique d'indépendance avec les HSIC.

On sait par l'un des théorèmes que la loi asymptotique de l'estimateur est une somme pondérée de $\chi^2(1)$. On peut donc poser le test suivant :

$$H_0 : P_{XY} = P_X \otimes P_Y,$$

La loi asymptotique de la statistique $m \widehat{\text{HSIC}}_V(X, Y)$ est une somme pondérée de variables de loi $\chi^2(1)$.

Pour un niveau de risque $\alpha \in (0, 1)$, on rejette l'hypothèse d'indépendance lorsque

$$m \widehat{\text{HSIC}}_V(X, Y) > c_{1-\alpha},$$

où $c_{1-\alpha}$ désigne le quantile d'ordre $1 - \alpha$ de la loi limite sous H_0 .

En pratique, cette loi asymptotique étant difficile à calculer exactement, [8] proposent de l'approcher par une loi Gamma dont les paramètres sont estimés à partir des données. Si $Q_{1-\alpha}$ désigne le quantile d'ordre $1 - \alpha$ de cette approximation, la région critique du test devient

$$m \widehat{\text{HSIC}}_V(X, Y) > Q_{1-\alpha}.$$

On rejette alors H_0 et on conclut à l'existence d'une dépendance entre X et Y . Sinon, on n'accepte pas H_1 et on reste sous l'hypothèse nulle.

Test des permutations. Le test des permutations est une méthode non paramétrique permettant de tester l'hypothèse nulle d'indépendance entre une entrée X_i et la sortie Y proposée par [12]. On pose :

$$H_0 : X_i \perp Y \quad \text{vs} \quad H_1 : X_i \not\perp Y.$$

L'idée fondamentale repose sur le fait que, sous H_0 , la statistique $\widehat{\text{HSIC}}(X_i, Y)$ estimée sur l'échantillon original ne devrait pas différer significativement de celle obtenue sur des échantillons où l'on a artificiellement brisé toute dépendance entre X_i et Y , puisqu'il n'y a déjà pas de

dépendance. C'est notamment ce qui a été fait par [4] avec des indices HSIC-ANOVA (ou cf. Annexe pour un exemple).

Sous l'hypothèse d'indépendance, les observations de Y peuvent être permutées aléatoirement sans modifier la distribution jointe des données. On construit alors B échantillons permutés

$$(X_i, Y^{[1]}), \dots, (X_i, Y^{[B]}),$$

où chaque $Y^{[b]}$ est obtenu en réordonnant aléatoirement les observations de Y .

La procédure du test est comme suit :

1. Calculer la statistique observée

$$T_{\text{obs}} = \widehat{\text{HSIC}}(X_i, Y).$$

2. Générer B permutations indépendantes de l'échantillon de sortie Y .
3. Pour chaque permutation $b = 1, \dots, B$, calculer

$$T_b = \widehat{\text{HSIC}}(X_i, Y^{[b]}).$$

4. Estimer la p -valeur par

$$p_B = \frac{1}{B} \sum_{b=1}^B \mathbf{1}_{\{T_b \geq T_{\text{obs}}\}}.$$

5. Rejeter H_0 au niveau α si

$$p_B < \alpha.$$

Les statistiques $\{T_b\}_{b=1}^B$ fournissent alors une approximation empirique de la distribution de $\widehat{\text{HSIC}}(X_i, Y)$ sous H_0 , permettant de déterminer directement la significativité de la dépendance observée.

Après avoir présenté les fondements théoriques des indices de Sobol et du critère HSIC, nous proposons dans la section suivante une comparaison numérique de ces deux approches. L'objectif est d'analyser leurs comportements respectifs sur plusieurs configurations, en particulier leur capacité à identifier et à hiérarchiser les variables influentes, ainsi que leur sensibilité à la nature des relations entre les entrées et la sortie. Cette étude permettra également de mettre en évidence les différences d'interprétation entre une approche fondée sur la décomposition de la variance et une mesure reposant sur la dépendance statistique.

2.4 Comparaison numérique entre Sobol et HSIC

Dans cette partie, on va comparer numériquement les indices de Sobol et le critère HSIC à partir de plusieurs modèles de simulation présentant des structures de dépendance et d'interaction différents.

Trois configurations sont considérées. La première repose sur la G -fonction, caractérisée par des entrées indépendantes et l'absence d'interactions. La deuxième utilise la fonction Friedman, pour laquelle les entrées sont indépendantes mais certaines variables interviennent conjointement, introduisant ainsi un effet d'interaction. Enfin, la troisième configuration reprend la fonction Friedman en introduisant cette fois des dépendances entre les variables d'entrée.

2.4.1 Sur la G -fonction (indépendance des entrées)

La première expérience repose sur la G -fonction qui a déjà été utilisée notamment par [11] dans un cadre d'AS global. Il s'agit d'un modèle scalaire $f : [0, 1]^d \rightarrow \mathbb{R}$ défini, pour un vecteur d'entrée $x = (x_1, \dots, x_d)$, par :

$$f(x) = \prod_{i=1}^d \frac{|4x_i - 2| + a_i}{1 + a_i}, \quad \text{où} \quad a_i = \frac{i-2}{2}, \quad \forall i = 1, \dots, d.$$


Les entrées X_i sont supposées indépendantes et identiquement distribuées selon $X_i \sim \mathcal{U}(0, 1)$, ce qui correspond au cadre standard de la littérature pour cette fonction. Dans nos simulations, on considère plusieurs dimensions $d \in \{5, 10\}$, plusieurs tailles d'échantillon $n \in \{100, 500, 1000\}$, ainsi que 30 répétitions indépendantes pour chaque couple (d, n) . On fixe de plus $a_1 = 99$, ce qui rend X_1 non influent pour cette fonction. On va se servir de X_1 comme référence de variable non-influente dans nos méthodes.

Sur ce modèle (et aussi le suivant), on va comparer trois indices : les indices de Sobol de premier ordre S_i , les indices de Sobol totaux S_{T_i} (estimés par la méthode de `sobolj2002`) et les indices normalisés R^2 -HSIC obtenus via `sensiHSIC`. Pour chaque configuration (d, n) , on calcule, sur les 30 répétitions, les jeux d'indices S_i , S_i^T et $R_{\text{HSIC},i}^2$, puis on trace leur boxplot afin de comparer leurs différence en distribution.

On calcule également les p-valeurs de test d'indépendance asymptotique et par permutations sur le HSIC via `testHSIC`. Comme on a déjà dit, la première composante X_1 joue le rôle de variable de référence : on s'attend à des indices S_1 et S_1^T proches de zéro, et on vérifie si $R_{\text{HSIC},1}^2$ et les p-valeurs associées détectent correctement cette absence d'influence, tout en observant comment cette performance évolue avec d , n et le nombre de répétitions.


Il est quand même important de noter que Sobol, dûe à son estimation Pick-Freeze, demande en réalité $2n$ tirages, en raison de la nécessité d'un deuxième plan d'expérience. On a décidé de se plier à ceci : pour chaque estimation Sobol S_1 et S_1^T , on a tiré 2 échantillons distincts et on ne les a jamais réutilisés. L'échantillon utilisé dans chaque répétition pour le HSIC est aussi encore un autre échantillon distinct des 2 premiers.

Indices de Sobol - d = 5




(a) $d = 5$

Indices de Sobol - d = 10




(b) $d = 10$

R^2 -HSIC - d = 5




(c) $d = 5$




(a) $d = 10$

Distribution des p-valeurs HSIC - $d=5$ - 30 rép.
 X_1 est non influent



(b) $d = 5$

Distribution des p-valeurs HSIC - $d=10$ - 30 rép.
 X_1 est non influent



(c) $d = 10$

FIGURE 4 – Indices de Sobol, indices $R^2\text{-HSIC}$ et taux de rejet des tests HSIC pour la G-fonction.

Les boxplots (a) et (b) montrent la répartition des indices de Sobol par variable sur les

30 répétitions, pour $d = 5, 10$. Première chose à noter : la variabilité des estimations grandit beaucoup lorsque le nombre de variables grandit et qu'on a un nombre faible de tirages. De plus, dans ce cas précis, on voit qu'il y a plus ou moins équivalence entre S_1 et S_1^T , c'est-à-dire que $S_1^T - S_1 \approx 0$, donc qu'il n'y a en effet pas d'interaction pour nos variables. Enfin, on voit bien que dans tous les cas, X_1 a un indice de 0 pour tout (n, d) .

Les boxplots (c) et (d) montrent eux les indices $R^2 - HSIC$. Une chose notable quand on a seulement ces indices est que $R^2 - HSIC(X_1, Y) \approx 0$, donc qu'on peut plutôt affirmer que $X_1 \perp Y$, mais il faut tout de même se réserver aux tests pour ça. On voit aussi que pour les petits n , le $R^2 - HSIC$ ne souffre pas de la grande variabilité dont Sobol a souffert. Il est plus précis pour des petits n .

Au niveau des tests de p-valeur sur les boxplots (e) et (f), on voit bien que pour X_1 , on reste sous H_0 dans tous les cas, donc on a bien non-influence donc indépendance entre X_1 et Y . Cependant, comme on aurait pu s'y attendre, pour $n = 100$, les tests n'ont pas encore le temps de converger, même pour le test de permutation. Ceci est d'autant plus vrai lorsque le nombre de variables d passe de 5 à 10. Là où 500 suffisait pour 5 variables, il faut passer à 1000 pour 10 variables.

2.4.2 Sur la fonction de Friedman (indépendance des entrées, interactions)


Le dernier exemple est la fonction de Friedman, introduite par lui même dans [6]. Elle est définie, pour $x = (x_1, \dots, x_d) \in [0, 1]^d$, par

$$f(x) = 10 \sin(\pi x_1 x_2) + 20(x_3 - 0,5)^2 + 10x_4 + 5x_5,$$


avec $X_i \sim \mathcal{U}(0, 1)$ indépendantes. Les variables X_1 à X_5 sont véritablement influentes, tandis que X_6 est muette (elle n'intervient pas dans la définition de f). Ce modèle inclut à la fois des effets non linéaires et des interactions (notamment entre X_1 et X_2), ce qui en fait un bon test pour voir comment Sobol et le HSIC se comportent dans un cadre un peu moins trivial.

La figure (a), montrant les indices de Sobol, met encore en évidence la grande variabilité de Sobol pour les petits n . Aussi, vu la fonction de Friedman, on est censé trouver interaction entre X_1 et X_2 . On voit ici que l'interaction commence à apparaître de manière distincte qu'à partir de $n = 500$ (donc en réalité 1000 tirages, comme on a pu expliquer précédemment).

Au niveau du HSIC (b), on voit qu'on est déjà, pour $n = 100$, en train d'exclure X_6 là où Sobol avait plus de mal avec des indices de premier ordre et total qui ne concordent pas. Sur les tests de p-valeurs (c), on voit encore que $n = 100$ semble trop faible pour qu'il y ait convergence des tests, amis que $n = 500$ suffit pour avoir un résultat satisfaisant : indépendance entre X_6 et Y seulement, les autres variables sont bien dépendants.




(a) Indices de Sobol.



(b) Indices $R^2 - HSIC$.

Distribution des p-valeurs HSIC - d=6 - 30 rép.
Indépendance des variables



(c) Taux de rejet des tests HSIC (asymptotique vs permutation)

FIGURE 5 – Sobol, $R^2 - HSIC$ et p-tests sur Friedman avec des variables indépendantes.

2.4.3 Sur la fonction de Friedman (dépendance des entrées et interaction)

On reprend le modèle précédent :

$$f(x) = 10 \sin(\pi x_1 x_2) + 20(x_3 - 0,5)^2 + 10x_4 + 5x_5,$$

au changement près qu'on va introduire de la dépendance dans les variables. On va poser des X_i gaussiennes standards, de manière à ce que X_1 et X_3 aient une covariance $\rho = 0.7$.

Il y a notamment [10] qui ont fait une étude plus poussée selon la corrélation du comportement des indices de Sobol (et de Shapley). Ici, on ne va se contenter que d'une valeur nominale pour voir ce qu'on peut en tirer avec le HSIC et Sobol.




FIGURE 6 – Indices R2-HSIC.

FIGURE 7 – R2-HSIC sur Friedman avec dépendance entre les variables.

On s'est éloigné du cadre théorique dans lequel on peut faire Sobol maintenant qu'on a dépendance entre les variables, donc on doit se contenter du HSIC.

Au niveau du HSIC, c'est moins brutal : X_3 l'emporte certes en terme de valeur mais ce n'est pas ce qui nous intéresse avec le HSIC. Le plus important est qu'on a X_1, X_3, X_4 qui ont des indices non-nuls, et donc que X_2, X_5 et X_6 seront sûrement indiqués non-influents par les tests.

On peut cependant dans ce cas passer par la théorie des jeux et faire du Sobol-Shapley. On crée le jeu coopératif (X , Variance de l'espérance conditionnelle) et on calcule donc les valeurs de Shapley pour le même n par l'algorithme classique qui parcourt toutes les permutations.

On peut maintenant interpréter librement ces indices. On peut donc voir que, même pour $n = 100$, on est quasiment à convergence des valeurs. Dans notre exemple, c'est apparemment X_3 (qui a une corrélation de 0,7 avec X_1) qui est le plus influent. Ce sont même les deux seules variables qui sont clairement influentes du système. Ces indices de Shapley permettent donc de sauver la mise dans un cas où la dépendance peut poser problème, comme on pourra le voir dans un système multi-niveaux plus tard.




FIGURE 8 – Valeurs de Sobol-Shapley sur l'exemple avec dépendance, calculés avec la fonction `ShapleyPermEx` du package `sensitivity`.

2.4.4 Sur un cas d'exemple : MARTHE

Maintenant qu'on a pu comparer le HSIC et voir ses avantages sur la théorie et sur des simulations, on peut essayer de mettre en pratique le HSIC sur le jeu de données MARTHE, récupéré ici : <https://www.sfu.ca/ssurjano/marthe.html>.

Le jeu de données MARTHE est issu du code de simulation numérique MARTHE (développé par le BRGM, Bureau de Recherches Géologiques et Minières), qui modélise le transport du Strontium-90 dans la nappe phréatique superficielle du site de stockage de déchets radioactifs de l'Institut Kourchatov à Moscou. Le code de simulation n'étant plus accessible, le jeu de données sert de référence pour tester des méthodes d'analyse de sensibilité et de propagation d'incertitudes.

Structure du jeu de données. Il comprend $n = 300$ observations, 20 variables d'entrée et 10 variables de sortie correspondant aux concentrations en contaminant mesurées à 10 puits d'observation : p102K, p104, p106, p2.76, p29K, p31K, p35K, p37K, p38 et p4b.

Variables d'entrée. Les 20 paramètres incertains sont répartis en plusieurs groupes physiques :

- **Conductivités hydrauliques** : 3 conductivités par couche (`per1`, `per2`, `per3`) et 4 par zone (`perz1`, `perz2`, `perz3`, `perz4`), toutes distribuées selon des lois $\mathcal{U}[1, 15]$ sauf `per2` $\sim \mathcal{U}[5, 20]$.
- **Dispersivités longitudinales et transversales** : $(d1, d2, d3) \sim \mathcal{U}[0.05, 2]$ et les dispersivités transversales associées $d_{ti} \sim \mathcal{U}[0.01 \cdot d_i, 0.1 \cdot d_i]$ — ces dernières sont donc dépendantes des longitudinales.
- **Coefficients de distribution volumique** : $(kd1, kd2, kd3)$ suivent des lois de Weibull de paramètres distincts.
- **Porosité** : `poros` $\sim \mathcal{U}[0.3, 0.37]$.
- **Infiltrations** : $(i1, i2, i3)$ avec des distributions emboîtées — $i1 \sim \mathcal{U}[0, 0.0001]$, $i2$

$\sim \mathcal{U}[i_1, 0.01]$, $i_3 \sim \mathcal{U}[i_2, 0.1]$ — introduisant une dépendance structurelle entre ces trois variables.

Ce jeu de données est particulièrement intéressant pour l'analyse de sensibilité car il présente des dépendances structurelles entre certaines entrées (dispersivités transversales, infiltrations emboîtées), ce qui constitue un cas réaliste où les hypothèses d'indépendance des méthodes classiques comme Sobol sont mises en défaut.

Pour ce qui va suivre, on va se réjouir d'un énième avantage des indices HSIC : il n'y a pas besoin de métamodèle. On peut donc les calculer directement dans ce contexte *given data*.

De plus, un premier travail d'analyse de sensibilité globale a déjà été faite par [21] avec des indices de Sobol calculés via un métamodèle. On va donc essayer de retrouver des résultats ressemblant les leurs par le HSIC, sans métamodèle.

On a dit précédemment que l'interprétation des HSIC était bizarre, surtout dans le ranking. De plus, on a des variables dépendantes entre elles ici. On a donc décidé de faire un `i_group` qui regroupe (`i1`, `i2`, `i3`), et 3 groupes `d1_group`, `d2_group`, `d3_group` qui regroupent ensemble (`di`, `dti`).

De cette manière, on a maintenant des groupes indépendants entre eux. On peut donc se servir de la propriété de mesure d'indépendance du HSIC par exemple ici.

Aussi, quand on pose des groupes, il se pose la question du noyau qu'on peut choisir. On a testé avec 2 noyaux de groupes : RBF produit, Matérn 3/2 produit.




FIGURE 9 – Indices HSIC (R^2 -HSIC) avec comme noyaux de groupe des produits de RBF.




FIGURE 10 – Indices HSIC (R^2 -HSIC) obtenus avec comme noyaux de groupe des produits de Matern 3/2.

Les résultats sont sensiblement les mêmes, et donc l'interprétation aussi pour les 2. Cependant il y a beaucoup de valeurs très petites, et comme on a pu le voir plus tôt, on ne peut pas vraiment conclure hâtivement en voyant uniquement les indices $R^2 - HSIC$. On peut utiliser le test des p-valeurs par permutation mentionné juste avant pour essayer de voir un peu plus loin.




FIGURE 11 – p-valeurs du test de permutation avec comme noyaux de groupes des produits de RBF.




FIGURE 12 – p-valeurs du test de permutation avec comme noyaux de groupes des produits de Matern 3/2.

On voit par un test à 5% qu'il y a significativité presque systématiquement sur les sorties des variables **igroup**, **kd1**, **kd2**. On ne peut pas vraiment voir plus loin ici. Cependant, en regardant de plus près pour les sorties, on peut se rassurer parce qu'on trouve des résultats similaires à ce qu'avaient fait [21]. Par exemple, avec un noyau RBF, on trouve pour la sortie **p104** que les variables contributives sont **kd1** et **igroup** et eux avaient trouvés (**kd1**(93%), **i3**(4%), **perz1**(3%)). Nos résultats concordent aussi sur les autres sorties en général. En tout cas, on conclut bel et bien notre interprétation par les tests de p-valeurs plutôt que les indices eux-mêmes. On peut se référer à l'annexe pour voir comment ça se passe sur ce dataset avec le HSIC-ANOVA ou HSIC-Shapley pour voir un peu plus loin.

2.5 Synthèse

Cette section a présenté deux familles importantes d'indices utilisés en analyse de sensibilité globale : les indices de Sobol et l'HSIC. Ces deux approches reposent toutefois sur des principes différents et présentent des avantages ainsi que des limites complémentaires.

Les indices de Sobol sont des indices fondés sur une décomposition de la variance. Leur principal intérêt réside dans leur interprétation directe : ils quantifient la part de variance de la sortie attribuable à une variable ou à une interaction entre plusieurs variables. Ils permettent notamment de distinguer les effets individuels, mesurés par les indices de premier ordre, des effets d'interaction, pris en compte par les indices totaux. Ils constituent ainsi une référence largement utilisée en analyse de sensibilité globale.

Cependant, les indices de Sobol classiques reposent sur l'hypothèse d'indépendance des variables d'entrée. Leur estimation peut également être coûteuse, car elle nécessite généralement un grand nombre d'évaluations du modèle, ce qui peut devenir problématique lorsque celui-ci est une boîte noire coûteuse à simuler. Enfin, leur interprétation est naturellement liée à la variance de la sortie : une dépendance ou un effet important qui ne se traduit pas par une contribution significative à la variance peut être difficile à détecter.

L'HSIC constitue une approche complémentaire. Fondé sur les méthodes à noyaux, il mesure la dépendance entre une entrée et une sortie sans supposer que cette relation soit linéaire ou monotone. Il peut donc détecter des structures de dépendance plus générales que les corrélations classiques et que certains indices fondés sur la variance. L'HSIC présente également l'intérêt de pouvoir être utilisé pour construire des tests d'indépendance.

Cette flexibilité s'accompagne néanmoins de plusieurs difficultés. La valeur de l'HSIC dépend du choix des noyaux et de leurs paramètres, ce qui peut compliquer la comparaison directe entre plusieurs variables. Contrairement aux indices de Sobol, son interprétation en termes de contribution à la variance n'est pas immédiate. De plus, son estimation peut être sensible à la taille de l'échantillon et son calcul, généralement fondé sur des matrices de Gram, peut devenir coûteux lorsque le nombre de données augmente. Enfin, dans le cadre d'un test d'indépendance, il est nécessaire de déterminer une règle de décision, par exemple à l'aide de permutations ou d'une approximation de la loi asymptotique.

Il n'existe donc pas un indice universellement supérieur aux autres. Le choix d'une mesure dépend notamment de la nature des variables d'entrée, de la structure de dépendance recherchée, du nombre de simulations disponibles et de l'objectif de l'analyse. Sobol est particulièrement adapté lorsque l'on recherche une décomposition interprétable de la variance, tandis que l'HSIC est intéressant lorsque l'on souhaite détecter une dépendance générale, notamment non linéaire ou non monotone. Une revue non exhaustive des différentes mesures d'analyse de sensibilité est proposée par [9].

Ces deux indices peuvent par ailleurs être étendus ou combinés avec d'autres méthodes. Dans le cas des indices de Sobol, les valeurs de Shapley fournissent par exemple une manière d'attribuer équitablement les effets principaux et les interactions entre les variables. Les indices de Sobol ont également été généralisés au cas de sorties multivariées et fonctionnelles par [7]. Dans un cadre multi-niveau, [22] proposent une extension appelée analyse de sensibilité hiérarchique, qui permet d'étudier l'influence des variables à différents niveaux d'un système.

Les généralisations ne se limitent pas aux sorties scalaires ou fonctionnelles. Il est également possible de considérer des sorties plus complexes, telles que des ensembles aléatoires. Par exemple, [5] construit des mesures HSIC adaptées à ce type de sorties, tandis que [15] étend les indices de Sobol au cas des ensembles aléatoires.

À ce stade, les méthodes présentées permettent donc d'identifier les variables les plus influentes et, dans le cas de l'HSIC, de tester l'existence d'une dépendance entre deux variables. Elles ne décrivent toutefois pas précisément la forme de cette dépendance. Savoir que deux variables sont dépendantes ne permet pas encore de déterminer si cette dépendance est linéaire, monotone, asymétrique ou caractérisée par une forte association dans les queues de distribution.

La question suivante est donc de savoir comment représenter et modéliser explicitement la structure de dépendance entre les variables. C'est l'objectif de la théorie des copules, qui permet de séparer les lois marginales des variables de leur structure de dépendance. Cette approche sera ensuite mobilisée dans le cadre des systèmes multi-niveaux afin d'étudier la propagation de la dépendance et de la sensibilité d'un niveau à l'autre.

3 Analyse de sensibilité dans un système multi-niveaux

La notion de système feed-forward a été introduite de manière informelle dans l'introduction. Nous en proposons désormais une définition plus rigoureuse et introduisons les outils nécessaires à son étude, afin de poser le cadre théorique permettant d'aborder le cœur du travail réalisé au cours de ce stage.

3.1 Systèmes feed-forward

Un système feed-forward est un système dans lequel l'information circule dans un seul sens, des entrées vers les sorties, sans rétroaction. Autrement dit, chaque variable de sortie dépend uniquement des variables qui la précèdent dans la chaîne de calcul, et aucune variable ne peut influencer directement ou indirectement une variable déjà utilisée pour la déterminer. On peut décomposer un tel système en sous-systèmes élémentaires :

$$Y^{(l)} = f^{(l)}(Y^{(l-1)}, X^{(l)}), \quad l = 1, \dots, L, \quad (30)$$

où $Y^{(l)}$ est la sortie du sous-système l , $f^{(l)}$ la fonction du sous-système, $X^{(l)}$ les entrées externes du niveau l , et $Y^{(0)} = X$ les entrées globales du système. La sortie finale est $Z = Y^{(L)}$. La structure feed-forward permet de décomposer l'analyse de sensibilité globale en analyses locales par sous-système, puis de propager les résultats de niveau en niveau. C'est cette approche que nous adopterons dans la suite de ce travail.




FIGURE 13 – Système feed-forward simple à 2 niveaux.

On peut illustrer cela sur un système simple à deux niveaux et trois entrées. On le décompose en trois sous-systèmes élémentaires :

- premier sous-système : $(X_1, X_2) \rightarrow Y_1$;
- deuxième sous-système : $(X_1, X_3) \rightarrow Y_2$;
- troisième sous-système : $(Y_1, Y_2, X_2) \rightarrow Z$.

L'objectif du stage consiste ainsi à étendre l'analyse de sensibilité à des systèmes plus complexes de ce type, afin d'en caractériser les mécanismes d'influence et de propagation.

3.2 Modélisation de la dépendance

On a vu que les indices de sensibilités permettaient en un sens de mesurer la dépendance, mais on peut aller plus loin en utilisant les copules. Elles vont permettre de mieux voir la dépendance entre les variables, puisqu'elles modélisent la dépendance elle-même.[13] fait une liste exhaustive des résultats sur les copules, ici nous ne présenterons que ce qui nous sera utile.

3.2.1 Théorie des copules

Définition 9 (Copule). Une copule d -dimensionnelle est une fonction

$$C : [0, 1]^d \longrightarrow [0, 1]$$

qui est une fonction de répartition sur $[0, 1]^d$ et dont toutes les marges sont uniformes sur $[0, 1]$.

Théorème 2 (Théorème de Sklar, 1959). Soit F la fonction de répartition jointe d'un vecteur aléatoire

$$(X_1, \dots, X_d)$$

dont les fonctions de répartition marginales sont $F_1, \dots, F_d$. Alors il existe une copule C telle que, pour tout $(x_1, \dots, x_d) \in \mathbb{R}^d$,

$$F(x_1, \dots, x_d) = C(F_1(x_1), \dots, F_d(x_d)). \quad (31)$$

Si les fonctions de répartition marginales $F_1, \dots, F_d$ sont continues, alors la copule C est unique.

Lorsque les marginales sont continues, les variables transformées

$$U_i = F_i(X_i), \quad i = 1, \dots, d,$$

sont uniformes sur $[0, 1]$, et leur fonction de répartition jointe est la copule :

$$C(u_1, \dots, u_d) = \mathbb{P}(U_1 \leq u_1, \dots, U_d \leq u_d).$$

La copule décrit ainsi la structure de dépendance entre les variables, indépendamment de leurs lois marginales.

Si une marginale F_i n'est pas continue, la variable $F_i(X_i)$ n'est pas nécessairement uniforme. On peut alors utiliser la transformée de probabilité randomisée

$$U_i = F_i(X_i^-) + V_i(F_i(X_i) - F_i(X_i^-)),$$

où les variables V_i sont indépendantes et suivent une loi $\mathcal{U}(0, 1)$. La variable U_i est alors uniforme sur $[0, 1]$. La copule C capture donc la structure de dépendance **indépendamment des lois marginales**. C'est la séparation entre comportement marginal et structure de dépendance qui fait leur intérêt. De plus, les copules sont lipschitziennes donc continues. Ceci découle de la caractérisation qu'en fait [17].

Proposition 6. Invariance par transformation bijective de la copule. Si l'on applique à chacune des composantes X_j une transformation continue et strictement croissante T_j , alors la copule du vecteur aléatoire n'est pas modifiée.

Démonstration. Soit $X = (X_1, \dots, X_d)$ un vecteur aléatoire de fonction de répartition jointe F_X et de marginales $F_{X_1}, \dots, F_{X_d}$. Par le théorème de Sklar, il existe une copule C_U telle que

$$F_X(x_1, \dots, x_d) = C_U(F_{X_1}(x_1), \dots, F_{X_d}(x_d)).$$

Posons

$$\tilde{X} = (T_1(X_1), \dots, T_d(X_d)),$$

où chaque T_j est continue et strictement croissante. Pour tout $x = (x_1, \dots, x_d) \in \mathbb{R}^d$, on a

$$F_{\tilde{X}}(x_1, \dots, x_d) = \mathbb{P}(T_1(X_1) \leq x_1, \dots, T_d(X_d) \leq x_d).$$

Comme chaque T_j est strictement croissante, on peut inverser les inégalités :

$$F_{\tilde{X}}(x_1, \dots, x_d) = \mathbb{P}(X_1 \leq T_1^{-1}(x_1), \dots, X_d \leq T_d^{-1}(x_d)).$$

Donc

$$F_{\tilde{X}}(x_1, \dots, x_d) = F_X(T_1^{-1}(x_1), \dots, T_d^{-1}(x_d)).$$

En appliquant la décomposition de Sklar à F_X , on obtient

$$F_{\tilde{X}}(x_1, \dots, x_d) = C_U(F_{X_1}(T_1^{-1}(x_1)), \dots, F_{X_d}(T_d^{-1}(x_d))).$$

Or les marginales de $\tilde{X}$ vérifient

$$F_{\tilde{X}_j}(x_j) = F_{X_j}(T_j^{-1}(x_j)).$$

Ainsi,

$$F_{\tilde{X}}(x_1, \dots, x_d) = C_U(F_{\tilde{X}_1}(x_1), \dots, F_{\tilde{X}_d}(x_d)).$$

□

La copule de $\tilde{X}$ est donc la même que celle de X . Elle est inchangée par toute transformation continue et strictement croissante appliquée séparément à chaque composante. De plus, si les marginales sont dérivables, la densité jointe de X s'écrit

$$f_X(x_1, \dots, x_d) = c_U(F_{X_1}(x_1), \dots, F_{X_d}(x_d)) \prod_{j=1}^d f_{X_j}(x_j) \quad (32)$$

où

$$c_U(u_1, \dots, u_d) = \frac{\partial^d C_U}{\partial u_1 \dots \partial u_d}(u_1, \dots, u_d). \quad (33)$$

En fait, c_U encode les dépendances internes dans un vecteur aléatoire. Nous allons nous servir de ces résultats pour mettre en place une méthode d'analyse de sensibilité dans notre système.

3.2.2 Mesures de concordance

On a vu que les copules permettent de modéliser la dépendance, mais si on revient à notre objectif de base qu'est le ranking, comment classe-t-on les variables ? Selon quelle mesure ?

Le coefficient de corrélation de Pearson mesure l'association linéaire entre deux variables aléatoires. Sous l'hypothèse de moments d'ordre deux finis, il est défini par

$$\rho_{kl} = (X_k, X_l) = \frac{(X_k, X_l)}{\sqrt{(X_k)(X_l)}}. \quad (34)$$

Il vérifie

$$-1 \leq \rho_{kl} \leq 1$$

et l'indépendance implique une corrélation nulle :

$$X_k \perp X_l \implies \rho_{kl} = 0.$$

Cependant, la réciproque est fautive en général. De plus, le coefficient de Pearson dépend des lois marginales et n'est invariant que par transformations affines strictement croissantes des variables. Il peut donc être nul en présence d'une dépendance non linéaire.

Dans le cadre des copules, on privilégie souvent des mesures fondées sur les rangs, telles que le tau de Kendall. Celui-ci mesure la concordance entre deux variables plutôt que leur association linéaire.

Définition 10 (Tau de Kendall). Soient (X_k, X_l) et $(\tilde{X}_k, \tilde{X}_l)$ deux copies indépendantes de la paire (X_k, X_l) . Le tau de Kendall est défini par

$$\tau_{kl} = \mathbb{P}\left[(X_k - \tilde{X}_k)(X_l - \tilde{X}_l) > 0\right] - \mathbb{P}\left[(X_k - \tilde{X}_k)(X_l - \tilde{X}_l) < 0\right]. \quad (35)$$

Le premier terme correspond à la probabilité que les deux paires soient concordantes, tandis que le second correspond à la probabilité qu'elles soient discordantes. Le tau de Kendall est invariant par transformations strictement croissantes des marges :

$$\tau(T_k(X_k), T_l(X_l)) = \tau(X_k, X_l),$$

pour toutes fonctions strictement croissantes T_k et T_l .

Ainsi, lorsque les variables sont continues, le tau de Kendall ne dépend que de la copule associée à la paire (X_k, X_l) et non des lois marginales. Si C_{kl} désigne cette copule, alors

$$\tau_{kl} = 4 \int_{[0,1]^2} C_{kl}(u, v) dC_{kl}(u, v) - 1. \quad (36)$$

ce qui montre que τ_{kl} ne dépend que du produit $C_{kl} \times c_{kl}$, donc seulement de la structure de dépendance de la paire (X_k, X_l) , sans faire intervenir les lois marginales.

En pratique, on estime le tau de Kendall à partir d'un échantillon

$$\left\{ (X_k^{(r)}, X_l^{(r)}) \right\}_{r=1}^n.$$

On remplace chaque observation par son rang :

$$R_k^{(r)} = \text{rang}(X_k^{(r)}), \quad R_l^{(r)} = \text{rang}(X_l^{(r)}).$$

ou par sa pseudo-observation, qui est son rang divisé par $(n+1)$. Pour deux observations $r < s$:

- la paire est **concordante** si

$$(R_k^{(r)} - R_k^{(s)})(R_l^{(r)} - R_l^{(s)}) > 0;$$

- la paire est **discordante** si

$$(R_k^{(r)} - R_k^{(s)})(R_l^{(r)} - R_l^{(s)}) < 0.$$

En l'absence d'égalité dans les échantillons, l'estimateur du tau de Kendall est alors

$$\hat{\tau}_{kl} = \frac{2}{n(n-1)} \sum_{1 \leq r < s \leq n} \text{sign} \left[(R_k^{(r)} - R_k^{(s)})(R_l^{(r)} - R_l^{(s)}) \right].$$

De manière équivalente,

$$\hat{\tau}_{kl} = \frac{N_C - N_D}{\binom{n}{2}},$$

où N_C et N_D désignent respectivement le nombre de paires concordantes et discordantes.

3.3 Méthode développée

Prenons un système multi-niveaux, c'est-à-dire des entrées $(X_1, \dots, X_d)$, des variables intermédiaires pour chaque niveau l , $(Y_1, \dots, Y_p)^{(l)}$ et une sortie Z scalaire. On suppose que les X_i sont indépendants entre eux. Les grandes lignes de la méthode qu'on suivra sont les suivantes, en se plaçant à chaque fois dans un sous-système successif.

- 1. Sélection des variables influentes par Sobol du premier niveau $X \rightarrow Y^{(1)}$
- 2. Construction d'un échantillon $Y'^{(1)}$ par estimation à noyau d'une copule conditionnelle $\widehat{c_{Y'^{(1)}|X}}$ puis calculer sélectionner par Shapley les variables les plus influentes sur ce niveau $Y'^{(1)} \rightarrow Y'^{(2)}$
- 3. Répéter 2. $\forall l$ en estimant $\widehat{c_{Y'^{(l)}|Y'^{(l-1)}}$ et en sélectionnant par Shapley les variables influentes sur le niveau suivant jusqu'à arriver au dernier niveau (qu'on pourra noter Z).
- 4. Faire une analyse de sensibilité directement sur $X \rightarrow Z$ par Sobol.

Cette méthode permet théoriquement de voir l'analyse de sensibilité entre X et Z et comment la sensibilité "se propage" le long du système.

Aussi, cette explication de la méthode est simpliste et ne prend pas en compte les techniques d'échantillonnage ou les détails sur l'estimation à noyau. Il se peut aussi qu'on ait une *variable partagée*, c'est-à-dire qui entre dans plusieurs niveaux du système à la fois. On va aussi essayer de détailler dans chaque exemple comment on les traite. Des travaux sont fait sur comment répartir les variables entre chaque niveau, notamment par [22] qui regardent la différence dans les indices de sensibilité entre chaque méthode. C'est d'ailleurs un de leurs exemples que nous allons reprendre pour comparer notre méthode avec leurs résultats et la valider.

Revenons maintenant à notre algorithme. Nous allons détailler chacune des étapes.

Étape 1 : Sélection des variables influentes par indices de Sobol. La première étape consiste à identifier, pour chaque variable intermédiaire $Y_i^{(1)}$ du premier niveau, les entrées X_j qui exercent une influence importante sur cette sortie.

Pour chaque paire $(X_j, Y_i^{(1)})$, on calcule l'indice de Sobol total

$$S_{T_j}^{Y_i^{(1)}} = 1 - \frac{\left(\mathbb{E}\left[Y_i^{(1)} \mid \mathbf{X}_{-j}\right]\right)}{\left(Y_i^{(1)}\right)},$$

où $\mathbf{X}_{-j}$ désigne l'ensemble des variables d'entrée autres que X_j . Cet indice mesure l'influence globale de X_j sur $Y_i^{(1)}$, en incluant son effet propre ainsi que ses éventuelles interactions avec les autres variables d'entrée.

Ce calcul suppose que les sous-modèles

$$Y_i^{(1)} = f_i(\mathbf{X})$$

sont disponibles ou peuvent être évalués. Dans le cas contraire, les sorties intermédiaires peuvent être reconstruites à partir des données disponibles, par exemple à l'aide d'une méthode d'estimation par noyau présentée dans la suite.

On retient alors X_j comme variable influente sur $Y_i^{(1)}$ si

$$S_{T_j}^{Y_i^{(1)}} > \delta_S,$$

où δ_S est un seuil fixé au préalable. On utilise souvent, sauf indication du contraire, $\delta_S = 0.2$. On note

$$\mathcal{X}\left(Y_i^{(1)}\right) = \left\{X_j : S_{T_j}^{Y_i^{(1)}} > \delta_S\right\}$$

l'ensemble des entrées retenues pour la variable intermédiaire $Y_i^{(1)}$.

Étape 2 : Construction des variables enrichies $Y'^{(1)}$ par copule conditionnelle à noyau. Pour chaque $Y_i^{(1)}$, on construit une variable enrichie $Y_i'^{(1)}$ qui absorbe l'information des entrées $X_j \in \mathcal{X}(Y_i^{(1)})$. Pour cela, on passe par des pseudo-observations sur lesquelles on estime une copule conditionnelle.

Pseudo-observations. On transforme $Y_i^{(1)}$ et les $X_j \in \mathcal{X}(Y_i^{(1)})$ en pseudo-observations uniformes :

$$U_{X_j}^{(k)} = \frac{\text{rang}(X_j^{(k)})}{n+1}, \quad U_{Y_i}^{(k)} = \frac{\text{rang}(Y_i^{(1,k)})}{n+1}.$$

Estimation de la copule conditionnelle. Soit $d_i = |\mathcal{X}(Y_i^{(1)})|$ et $h = n^{-1/(d_i+4)}$ la fenêtre de Silverman. L'estimateur à noyau d'une densité conditionnelle de la variable uniformisée est donné par :

$$\hat{c}_{Y_i^{(1)}|\mathbf{X}_S}(u_Y | \mathbf{u}_S) = \frac{\sum_{k=1}^n K_h(\mathbf{u}_S - \mathbf{U}_S^{(k)}) \cdot K_h(u_Y - U_{Y_i}^{(k)})}{\sum_{k=1}^n K_h(\mathbf{u}_S - \mathbf{U}_S^{(k)})},$$

où $K_h(\mathbf{t}) = \prod_j h^{-1} \phi(t_j/h)$ et ϕ est la densité $\mathcal{N}(0, 1)$. La fonction de répartition conditionnelle associée est,

$$\hat{C}_{Y_i^{(1)}|\mathbf{X}_S}(u_Y | \mathbf{u}_S) \approx \frac{\sum_{k=1}^n K_h(\mathbf{u}_S - \mathbf{U}_S^{(k)}) \cdot \mathbf{1}(U_{Y_i}^{(k)} \leq u_Y)}{\sum_{k=1}^n K_h(\mathbf{u}_S - \mathbf{U}_S^{(k)})}.$$

Construction de $Y_i'^{(1)}$. Pour chaque observation i , on résout numériquement via **uniroot** sur $\mathbf{R}$ pour $\hat{u}_{Y_i'}^{(i)}$:

$$\hat{C}_{Y_i^{(1)}|\mathbf{X}_S}(\hat{u}_{Y_i'}^{(i)} | \mathbf{U}_S^{(i)}; \{(\mathbf{U}_S^{(k)}, U_{Y_i}^{(k)})\}_{k \neq i}) = U_{Y_i}^{(i)},$$

puis on retransforme dans l'échelle originale :

$$Y_i'^{(1,i)} = \hat{F}_{Y_i^{(1)}}^{-1}(\hat{u}_{Y_i'}^{(i)}).$$

La qualité de la construction est vérifiée empiriquement par le τ de Kendall $\hat{\tau}(Y_i^{(1)}, Y_i'^{(1)})$, qui doit être proche de 1, et par l'ajustement d'une copule bivariable paramétrique sur $(Y_i^{(1)}, Y_i'^{(1)})$ par critère AIC. Ce fitting se fait par la fonction **bicop** du package **rvinecopulib**.

Étape 3 : Valeurs de Shapley entre les niveaux. Une fois les variables enrichies $Y_i'^{(1)}$ construites, on quantifie leur influence respective sur la sortie Z (ou sur le niveau suivant $Y^{(2)}$ dans un système à plus de deux niveaux) par les valeurs de Shapley. On définit un jeu coopératif (N, v) avec $N = \{Y_1'^{(1)}, \dots, Y_d'^{(1)}\}$ et la fonction caractéristique :

$$v(S) = \frac{\text{Var}(\mathbb{E}[Z | \mathbf{Y}_S'^{(1)}])}{\text{Var}(Z)}.$$

La valeur de Shapley de $Y_i'^{(1)}$ est :

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} [v(S \cup \{i\}) - v(S)].$$

Les valeurs de Shapley ϕ_i permettent alors de comparer l'importance relative des $Y_i'^{(1)}$ vis-à-vis de Z , en tenant compte des interactions entre variables intermédiaires.

Pour estimer $v(S)$ sans modèle analytique de Z depuis $\mathbf{Y}'^{(1)}$, on utilise l'estimateur KDE de l'espérance conditionnelle :

$$\hat{\mathbb{E}}[Z \mid \mathbf{Y}_S'^{(1)} = \mathbf{y}_S] = \sum_{k=1}^n w_k(\mathbf{y}_S) \cdot Z^{(k)}, \quad w_k(\mathbf{y}_S) = \frac{K_h(\hat{\mathbf{u}}_S - \mathbf{U}_S^{(k)})}{\sum_l K_h(\hat{\mathbf{u}}_S - \mathbf{U}_S^{(l)})}.$$

Le tirage conditionnel requis par l'algorithme de Shapley est réalisé ici par échantillonnage pondéré à noyau : chaque observation k reçoit un poids $K_h(\hat{\mathbf{u}}_{S^c} - \mathbf{U}_{S^c}^{(k)})$ proportionnel à sa proximité avec le point de conditionnement via notre noyau choisi. On utilisera aussi la fonction `ShapleyPermEx` ou `ShapleyPermRand` du package `sensitivity` dans notre code, selon si l'on veut utiliser l'algorithme `ApproShapley` ou non.

Pour notre premier exemple, on n'aura pas à itérer cette opération car dans l'optique d'illustrer la méthode il est plus logique de simplifier notre cas. La méthode reste cependant réitérable, mais il y a alors des soucis qui peuvent émerger : l'accumulation de l'erreur sur nos indices par le fait qu'on ne prenne pas des vraies valeurs pour calculer sur le niveau suivant, le traitement des variables partagées ou l'erreur liée à l'estimation non-paramétrique qui peut augmenter si l'on a beaucoup d'entrées influentes sur un niveau. On peut donc résumer ce qu'on fait sur ce dit-niveau via le flowchart suivant.

Etape 4 : Analyse directe $\mathbf{X} \rightarrow Z$ Il y a 2 cas : Si l'on dispose la fonction modèle tel que $Z = f(X)$, on peut directement calculer des indices de Sobol simplement. Sinon, nous appliquons la méthodologie précédente directement au niveau global $\mathbf{X} \rightarrow Z$, sans passer par la décomposition hiérarchique en $\mathbf{Y}'^{(l)}$. Ceci sert à voir les variables les plus influentes globalement dans le système multi-niveaux sans prendre en compte ce qui se passe à l'intérieur du système,

Construction de Z' et diagnostic. On construit Z' par inversion de la copule conditionnelle estimée $\hat{C}_{Z|\mathbf{X}}$, exactement comme pour les $Y_i'^{(1)}$ à l'étape précédente. Le τ de Kendall $\hat{\tau}(Z, Z')$ et l'erreur $\delta Z = \frac{Z' - Z}{Z}$ servent d'indicateurs de qualité de l'estimation.

Fonction modèle pour `shapleyPermEx`. Comme on veut résoudre le cas où on ne dispose pas d'un évaluateur direct de Z depuis $\mathbf{X}$, la fonction modèle pour `shapleyPermEx` est l'estimateur KDE de l'espérance conditionnelle :

$$\hat{\mathbb{E}}[Z \mid \mathbf{X}_S = \mathbf{x}_S] = \sum_{k=1}^n w_k(\mathbf{x}_S) \cdot Z^{(k)}, \quad w_k(\mathbf{x}_S) = \frac{K_h(\hat{\mathbf{u}}_S - \mathbf{U}_S^{(k)})}{\sum_l K_h(\hat{\mathbf{u}}_S - \mathbf{U}_S^{(l)})},$$

où $\hat{u}_{S,j} = \hat{F}_{X_j}(x_{S,j})$ est la pseudo-observation de $x_{S,j}$ via sa ECDF empirique. Cette fonction modèle est cohérente avec la construction de Z' : les deux utilisent la même copule KDE, Z' étant le quantile conditionnel et `model`($\mathbf{x}_S$) l'espérance conditionnelle.

Résumé et flowchart La méthode proposée repose sur une analyse successive des différents niveaux du système feed-forward. À chaque niveau, les variables influentes sont d'abord sélectionnées, puis les sorties intermédiaires sont reconstruites à partir d'une estimation de copule conditionnelle. Les variables reconstruites servent ensuite d'entrées pour l'analyse du niveau suivant.

Au premier niveau, la sélection repose sur les indices de Sobol totaux, afin d'inclure les effets d'interaction entre les entrées. Aux niveaux suivants, les valeurs de Shapley sont utilisées pour répartir la contribution entre les variables intermédiaires et les éventuelles variables d'entrée partagées. Après chaque reconstruction, un diagnostic fondé sur le tau de Kendall, l'ajustement

d'une copule bivariée et l'erreur relative permet d'évaluer la qualité de l'approximation. La procédure est répétée jusqu'au dernier niveau, puis comparée à une analyse directe de la relation $\mathbf{X} \rightarrow Z$.




FIGURE 14 – Schéma général de la méthode d'analyse de sensibilité Les variables influentes sont sélectionnées au premier niveau par les indices de Sobol totaux puis, aux niveaux suivants, par les valeurs de Shapley. Les sorties intermédiaires sont reconstruites à partir de copules conditionnelles estimées par KDE.

3.4 Validation sur un exemple analytique

Pour mettre en pratique sur un exemple notre méthode, nous allons maintenant considérer le système suivant, que l'on reprend à [22]. De leurs côtés, ils ont suivi une méthode laborieuse combinant expansion en polynômes du chaos, transformation de Rosenblatt, estimation de copules vignes, et régression. L'avantage de notre méthode est qu'elle est beaucoup plus *straightforward*, et permet de trouver des résultats similaires tout en permettant de pouvoir rééchantillonner sur les niveaux supérieurs.




Fig. 7 System structure for example 1

FIGURE 15 – Système feed-forward repris sur le papier de HSA de **Zhu et al.(2021)**

On considèrera aussi, comme eux, quatre variables d'entrée indépendantes avec les mêmes lois :

$$X_1 \sim \mathcal{N}(1, 0.1), \quad X_2 \sim \mathcal{N}(2, 0.1), \quad X_3 \sim \mathcal{N}(3, 0.1), \quad X_4 \sim \mathcal{N}(4, 0.1).$$

Le système est ensuite défini en deux niveaux. Au niveau bas, on introduit trois sous-systèmes :

$$Y_1 = 2X_1 - (X_1X_2)^\nu + 10X_3, \quad (37)$$

$$Y_2 = X_1^2 + 2X_2, \quad (38)$$

$$Y_3 = 3X_1 + \sqrt{X_2}. \quad (39)$$

Au niveau haut, la sortie finale est donnée pour certains ω et ν que l'on choisira comme eux par

$$Z = X_4Y_1^\omega + X_4^2Y_2^\omega + 2X_4^2Y_3^\omega + 10X_4^2X_3^\omega.$$

On peut voir que la variable X_3 est partagée dans les deux niveaux : sur $X \rightarrow Y$ et $Y \rightarrow Z$. Nous allons prendre le parti de la prendre en compte dans les calculs des indices des 2 niveaux pour pouvoir comparer le plus possible avec des résultats déjà existant par d'autres méthodes. On fixe $n = 1000$.

Grâce à la méthode développée, on a pu isoler le système de niveau supérieur et pu le transformer de la manière suivante.




FIGURE 16 – Système artificiel du deuxième niveau du système originel

Voyons donc dans un premier temps les résultats qu'on a sur le niveau supérieur, pour les différentes valeurs de ω et ν .




FIGURE 17 – $\omega = 2, \nu = 0$




FIGURE 19 – $\omega = 2, \nu = 2$




FIGURE 18 – $\omega = 1, \nu = 0$




FIGURE 20 – $\omega = 1, \nu = 2$

Ce sont les figures des valeurs de Shapley calculés sur les Y' reconstruit, mais qu'on a labellé avec les anciens noms de variable pour des soucis de clarté et d'interprétation, le but étant de faire de l'analyse de sensibilité dans le système initial.

On voit donc ici, comme on pouvait s'en douter en regardant les équations du système, que sur le niveau $Y \rightarrow Z$, le paramètre ω prédomine sur ν . Comme on peut le voir de manière encore plus frappante dans la table 1, les indices sont les mêmes à quatre chiffres significatifs près si on change ν , qui est le paramètre d'interaction entre X_1 et X_3 dans Y_1 .

On peut valider nos résultats, du moins sur le cas $\omega = 2, \nu = 2$ en comparant aux résultats obtenus sur le niveau haut par [22]. Eux malheureusement ne montrent que les résultats du système $Y \rightarrow Z$ que pour ce cas, mais sont plus exhaustifs pour le niveau $X \rightarrow Z$.

TABLE 1 – Résultats de la réduction de niveau par copule KDE après une sélection des variables influentes par indices de Sobol totaux ($S_j^T > 0.2$). Pour chaque combinaison de paramètres (ω, ν) et chaque variable intermédiaire Y_i , on reporte les entrées retenues comme influentes, le τ de Kendall empirique $\hat{\tau}(Y_i, Y'_i)$ mesurant la qualité de la construction KDE, la famille de copule paramétrique AIC-optimale ajustée sur le couple (Y_i, Y'_i) et son τ associé, ainsi que le τ de Kendall global $\hat{\tau}(Z, Z')$ mesurant la fidélité de la reconstruction de la sortie.

ω	ν	Y_i	X_j retenus	$\hat{\tau}(Y_i, Y'_i)$	Copule (Y_i, Y'_i)	$\hat{\tau}(Z, Z')$
1	0	Y_1	X3	0.92	bb1 (0.9177)	0.9418
		Y_2	X1, X2	0.96	gumbel (0.9618)	
		Y_3	X1	0.96	t (0.9632)	
1	2	Y_1	X3	0.92	bb1 (0.9177)	0.9418
		Y_2	X1, X2	0.96	gumbel (0.9618)	
		Y_3	X1	0.96	t (0.9632)	
2	0	Y_1	X3	0.92	bb1 (0.9177)	0.6117
		Y_2	X1, X2	0.96	gumbel (0.9618)	
		Y_3	X1	0.96	t (0.9632)	
2	2	Y_1	X3	0.92	bb1 (0.9177)	0.6117
		Y_2	X1, X2	0.96	gumbel (0.9618)	
		Y_3	X1	0.96	t (0.9632)	

Notes. $\hat{\tau}(Y_i, Y'_i)$: τ de Kendall entre la variable originale Y_i et la variable enrichie Y'_i : proche de 1 si l'estimation KDE est fidèle. Copule (Y_i, Y'_i) : famille paramétrique ajustée par AIC sur le couple (Y_i, Y'_i) avec le τ du paramètre estimé entre parenthèses. $\hat{\tau}(Z, Z')$: τ de Kendall entre la sortie originale Z et la sortie reconstruite $Z' = g(X_3, X_4, Y'_1, Y'_2, Y'_3; \omega)$, identique pour les trois Y_i d'une même configuration (ω, ν) .

Du côté du niveau bas, on peut évidemment utiliser Sobol sur le niveau $X \rightarrow Z$ car on connaît la fonction analytique g , mais on se met dans un cadre où on ne connaît pas la fonction et on essaie de l'approximer par notre méthode, et on compare avec les indices de Sobol calculés avec la vraie fonction g comme on a fait précédemment, puis on verra la fidélité de la reconstruction via un tau de Kendall. On va évidemment aussi comparer avec les résultats obtenus par [22].




FIGURE 21 — $\omega = 2, \nu = 0$




FIGURE 22 — $\omega = 1, \nu = 0$




FIGURE 23 — $\omega = 2, \nu = 2$




FIGURE 24 — $\omega = 1, \nu = 2$

On obtient donc sur le niveau bas des résultats sensibles au changement du paramètre ν , c'est assez logique : il influe sur l'écriture de Z en fonction des X . Ce n'était pas vraiment le cas pour le niveau $Y \rightarrow Z$.

En comparant aux résultats du papier de [22], on trouve les mêmes résultats au niveau du ranking sauf dans le cas $\omega = 2, \nu = 2$. On trouve cependant que la reconstruction de Z' par notre méthode est assez cohérente avec la variable Z initiale comme dans tous les cas.

On a essayé de voir plus loin sur le cas $\omega = 2, \nu = 2$. On s'est donc servi du fait qu'on connaisse la fonction analytique g pour calculer les vrais indices et non les estimations. C'est ce qui reviendrait à leur procédure *AIO* dans leur papier. On trouve cependant des résultats qui confirment nos résultats par notre méthode d'estimation via copule KDE et pas la leur, comme le montre la figure suivante. Ceci pose un malaise.




FIGURE 25 – Indices de Sobol sur le système $X \rightarrow Z$ calculés via la vraie formule analytique de Z en fonction de X . Prenant ces résultats comme comparatif de référence, on peut dire que notre méthode est donc validée. Les résultats sont proches des vrais indices dans ce cas comme dans les autres, voir les tableaux ci-dessous.

TABLE 2 – Tableau récapitulatif du niveau $X \rightarrow Z$, Corrélation $\hat{\tau}$ et indices de Sobol S^1 , S^T , modèle KDE vs modèle explicite.

ω	ν	X_j	$\hat{\tau}$		Sobol S^1		Sobol S^T	
			$\hat{\tau}(X_j, Z)$	$\hat{\tau}(X_j, Z')$	$S_j^{1,Z}$	$S_j^{1,Z'}$	$S_j^{T,Z}$	$S_j^{T,Z'}$
1	0	X1	0.1905	0.1911	0.0996	0.1574	0.0937	0.0796
		X2	0.0639	0.0652	-0.0330	0.1076	0.0094	0.0082
		X3	0.2755	0.2873	0.1723	0.2476	0.2106	0.1749
		X4	0.6229	0.6372	0.7069	0.7374	0.7696	0.6428
1	2	X1	0.1704	0.1713	0.0755	0.1401	0.0755	0.0645
		X2	0.0532	0.0551	-0.0450	0.1026	0.0066	0.0057
		X3	0.2815	0.2931	0.1794	0.2537	0.2210	0.1819
		X4	0.6317	0.6460	0.7184	0.7487	0.7891	0.6546
2	0	X1	0.2439	0.2419	0.1102	0.1852	0.1474	0.1228
		X2	0.0518	0.0672	-0.0309	0.0999	0.0072	0.0078
		X3	0.5572	0.5649	0.5849	0.6310	0.6726	0.5474
		X4	0.3129	0.3331	0.2343	0.3290	0.2601	0.2267
2	2	X1	0.1221	0.1206	-0.0278	0.0722	0.0365	0.0320
		X2	-0.0131	0.0046	-0.0853	0.0791	0.0005	0.0001
		X3	0.6122	0.6207	0.6844	0.7065	0.7929	0.6322
		X4	0.3317	0.3521	0.2392	0.3449	0.2982	0.2527

On a ainsi une nouvelle méthode mise en place qui permet de faire de l'analyse de sensibilité sur plusieurs systèmes à la fois. Les avantages sont que cette méthode est non-paramétrique, assez *straightforward* dans le sens où on peut l'appliquer tant qu'on a des variables X_i indépendantes entre elles et sans aucune hypothèse sur les niveaux supérieurs (sauf la conception feed-forward) et que contrairement au papier cité, on ne doit pas passer par beaucoup de méthodes différentes (décomposition en polynôme du chaos, transformation de Rosenblatt, copules vignes, ...) pour arriver à un résultat.

TABLE 3 – Écarts modèle KDE/explicite sur les indices de Sobol, dépendance Z - Z' et erreur de reconstruction. On voit que le modèle créé est assez proche des données réelles, et donc que les indice calculés sont interprétables.

ω	ν	X_j	ΔS^1	ΔS^T	$\tau_{ZZ'}$	$ \delta \bar{Z} $
1	0	X1	-0.0578	0.0141	0.9643	0.0266
		X2	-0.1406	0.0012		
		X3	-0.0753	0.0357		
		X4	-0.0305	0.1268		
1	2	X1	-0.0646	0.0110	0.9646	0.0267
		X2	-0.1476	0.0009		
		X3	-0.0743	0.0391		
		X4	-0.0303	0.1345		
2	0	X1	-0.0750	0.0246	0.9645	0.0333
		X2	-0.1308	-0.0006		
		X3	-0.0461	0.1252		
		X4	-0.0947	0.0334		
2	2	X1	-0.1000	0.0045	0.9654	0.0335
		X2	-0.1644	0.0004		
		X3	-0.0221	0.1607		
		X4	-0.1057	0.0455		

On cherchait surtout à valider notre méthode avec cet exemple, et le fait d'avoir 4 systèmes à la fois ne rendait pas simple l'interprétation. La suite va être plus axée interprétation, en analysant un système en cascade et en interprétant plus sérieusement les résultats de l'analyse de sensibilité réalisé dessus.

3.5 Sur un système en cascade

On reprend un système en cascade pour à nouveau utiliser notre méthode, que l'on retrouve dans [16]. Eux étudient ce système dans un contexte de surrogate model tel que les processus gaussiens.




Figure 14: Test case 3: cascade-like SoS structure with 16 global inputs and 4 solvers.

FIGURE 26 – Système en cascade repris de [16].

On va également reprendre leurs équations et lois sur les entrées.

Le système considéré est en fait un système feed-forward comportant 16 entrées globales et quatre solveurs ou niveaux organisés en cascade, comme représenté sur la figure. Les entrées globales sont indépendantes et suivent des lois uniformes sur $[0, 1]$:

$$X_1, \dots, X_{16} \stackrel{\text{i.i.d.}}{\sim} \mathcal{U}([0, 1]).$$

Niveau 1 : fonction Sobol-G.

$$Y_1 = \prod_{k=1}^5 \frac{|4X_k - 2| + a_k}{1 + a_k}, \quad \mathbf{a} = (12, 2, 3, 4, 45). \quad (40)$$

Y_1 ne dépend que de $X_1, \dots, X_5$. Le vecteur $\mathbf{a}$ contrôle l'importance de chaque entrée : plus a_k est petit, plus X_k est influent. Ici X_2 est la plus influente ($a_2 = 2$) et X_5 la moins ($a_5 = 45$).

Niveau 2 : fonction d'Ishigami.

$$Y_2 = \sin(Y_1) + 7 \sin^2(X_6) + 0.1 X_7^4 \sin(Y_1). \quad (41)$$

Y_2 dépend de Y_1 (sortie du niveau 1), et de deux nouvelles entrées globales X_6 et X_7 . La dépendance en Y_1 est non-linéaire et implique une interaction avec X_7 via le terme $X_7^4 \sin(Y_1)$.

Niveau 3 : mélange polynôme et arctan.

$$Y_3 = X_8^2 \arctan(1 - X_{12}) + X_9 X_{10} X_{11}^3 + 3Y_2. \quad (42)$$

Y_3 dépend de Y_2 (sortie du niveau 2) via le terme linéaire $3Y_2$, et de cinq nouvelles entrées globales $X_8, \dots, X_{12}$.

Niveau 4 :s sortie finale.

$$Z = \sin(X_{16}) X_{15} + Y_3 X_{13} + X_{14}. \quad (43)$$

Z dépend de Y_3 (sortie du niveau 3) et de quatre nouvelles entrées globales $X_{13}, \dots, X_{16}$.

Dépendances explicites. En substituant les niveaux les uns dans les autres, chaque sortie intermédiaire dépend des entrées globales suivantes :

$$\begin{aligned} Y_1 &= f_1(X_1, X_2, X_3, X_4, X_5), \\ Y_2 &= f_2(Y_1(X_1, \dots, X_5), X_6, X_7), \\ Y_3 &= f_3(Y_2(X_1, \dots, X_7), X_8, X_9, X_{10}, X_{11}, X_{12}), \\ Z &= f_4(Y_3(X_1, \dots, X_{12}), X_{13}, X_{14}, X_{15}, X_{16}). \end{aligned}$$

La sortie finale Z dépend donc de la totalité des 16 entrées globales, mais de façon *hiérarchisée* : $X_1, \dots, X_5$ n'influencent Z qu'indirectement, via la chaîne $Y_1 \rightarrow Y_2 \rightarrow Y_3 \rightarrow Z$.

Ce système constitue un cas test pertinent pour notre méthode hiérarchique, car il combine :

- un premier niveau avec une fonction de type Sobol, dont la structure de sensibilité est bien connue ;
- un deuxième niveau non linéaire et fortement interactif (Ishigami) ;
- deux niveaux supplémentaires mêlant produits polynomiaux et fonctions trigonométriques

Dans la suite, on applique notre méthode en quatre étapes :

1. Analyse de sensibilité de $X_{1:5}$ vers Y_1 par indices de Sobol, et sélection des entrées influentes.
2. Construction de Y_1' par copule conditionnelle à noyau, puis analyse de sensibilité par valeurs de Shapley de (Y_1', X_6, X_7) vers Y_2 .
3. Construction de Y_2' , puis analyse Shapley de $(Y_2', X_8, \dots, X_{12})$ vers Y_3 .
4. Construction de Y_3' , puis analyse Shapley de $(Y_3', X_{13}, \dots, X_{16})$ vers Z , et comparaison avec une analyse directe $X_{1:16} \rightarrow Z$.

Les résultats numériques et graphiques de cette application sont présentés dans la section suivante. On fixera $n = 10000$.




FIGURE 27 – Niveau 1 — $X \rightarrow Y_1$ (Sobol). Les variables importantes de ce niveau sont X_2 , X_3 et X_4 .




FIGURE 28 – Niveau 2 — $Y_1' \rightarrow Y_2$ (Shapley). La seule variable importante de ce niveau est X_6 .




FIGURE 29 – Niveau 3 — $Y_2' \rightarrow Y_3$ (Shapley). La seule variable influente est Y_2 .




FIGURE 30 – Niveau 4 — $Y_3' \rightarrow Z$ (Shapley). Les variables influentes ici sont Y_3 et X_{13} .

FIGURE 31 – Analyse de sensibilité par niveau pour le système en cascade à 4 niveaux. Les quatre sous-figures montrent les contributions des variables à chaque étage de la hiérarchie : indice de Sobol pour le premier niveau, valeurs de Shapley pour les trois niveaux suivants.




FIGURE 32 – Analyse de sensibilité directe $X \rightarrow Z$ par valeurs de Shapley sur l'ensemble des 16 entrées globales. On retrouve les variables X_6 et X_{13} comme variables influentes. par niveaux de la figure 31.

En appliquant notre méthode sur ce système en cascade, on peut conclure plusieurs choses.

- L'analyse directe $X \rightarrow Z$ retient bien des variables importantes qu'on a pu trouver dans des niveaux intermédiaires. Surtout celles du niveau 2 et 3, pas le premier.
- L'analyse du dernier niveau, le niveau 4, nous dit que les variables X_{13} et Y'_3 sont influentes. On sait donc à ce moment que les variables d'entrées influentes du système sont celles ayant un grand poids dans Y'_3 , et X_{13} .
- L'analyse du niveau 3 nous dit que du point de vue de Y_3 , la seule variable importante est Y'_2 . Ceci veut dire qu'aucune des variables X_8 jusque X_{12} ne sont pas influentes non plus. On peut donc transcrire au niveau 4 ce qu'on sait sur le niveau 3 : la variable X_{13} est influente de manière directe pour Z , et la variable Y_2 est influente à travers Y_3 pour Z .
- L'analyse du niveau 2 nous dit que du point de vue de Y_2 , l'unique variable importante est X_6 . Ceci veut dire que Y_1 n'a pas de poids dans la suite de la chaîne de solveurs, et donc que les variables importantes au niveau 1 entre X et Y_1 n'influencent pas sur la suite de la chaîne.

Si l'on retranscrit du point de vue du niveau 4, c'est-à-dire la sortie Z , on a alors que :

- Aucune des entrées X_1 à X_6 ne sont influentes pour Z , et donc a fortiori Y_1 non plus.
- Parmi les entrées du niveau 2, seul X_6 est influent. On peut donc dire que pour Z , la variable X_6 influe depuis le niveau 2.
- Parmi les entrées du niveau 3, seul Y'_2 porte un indice de Shapley important. Ceci veut dire que seulement les variables importantes du niveau 2, donc en fait X_6 , sont influentes sur la sortie Y_3 . Du point de vue de Z , on n'a donc pas de variable influente qui vienne du niveau 3.

En somme, du point de vue de la sortie finale, on a donc que le système admet 2 variables d'entrée à laquelle la réponse est sensible : X_6 et X_{13} . De plus, on sait comment leur sensibilité est transportée dans le système : le niveau 2 est complètement déterminé par X_6 et le niveau 3 est déterminé à parts presque égales par X_6, X_{13} .

TABLE 4 – Récapitulatif des analyses de sensibilité par niveau ($n = 10000$).

Niveau	Cible	X_j / Joueur	$\hat{\phi}_j$	$se(\hat{\phi}_j)$	S^1	S^T	$\hat{\tau}(\cdot, \text{Cible})$
Niveau 1	Y1	X1			0.0055	0.0285	
		X2			0.4741	0.5220	
		X3			0.2712	0.2987	
		X4			0.1531	0.1947	
		X5			-0.0260	0.0023	
Niveau 2	Y2	Y1'	0.0446	-0.1094	0.0106	0.0076	0.0801
		X6	0.9803	0.8133	0.9935	0.8928	0.9250
		X7	-0.0249	-0.1754	-0.0374	0.0003	0.0159
Niveau 3	Y3	Y2'	0.9852	0.7976	0.9986	0.9802	0.9514
		X8	0.0024	-0.1431	0.0137	0.0001	0.0037
		X9	-0.0019	-0.1458	0.0048	0.0003	0.0079
		X10	0.0010	-0.1443	0.0029	0.0001	0.0017
		X11	0.0070	-0.1390	0.0176	0.0008	0.0211
		X12	0.0063	-0.1382	0.0293	0.0003	-0.0137
Niveau 4	Z	Y3'	0.4897	0.3020	0.4564	0.4736	0.4507
		X13	0.5285	0.3417	0.5134	0.5296	0.5402
		X14	0.0027	-0.1650	0.0191	0.0070	0.0674
		X15	-0.0198	-0.1844	0.0190	0.0024	0.0398
		X16	-0.0011	-0.1719	-0.0094	0.0013	0.0369
Direct	Z	X1	0.0075	-0.0060	-0.0063	0.0001	-0.0055
		X2	0.0078	-0.0064	0.0638	0.0001	0.0018
		X3	-0.0056	-0.0232	-0.0061	0.0002	-0.0020
		X4	-0.0011	-0.0146	0.0017	0.0001	-0.0019
		X5	-0.0126	-0.0281	-0.0283	0.0002	0.0076
		X6	0.4704	0.4570	0.4978	0.4807	0.4433
		X7	-0.0022	-0.0185	-0.0222	0.0004	0.0101
		X8	0.0013	-0.0134	-0.0822	0.0002	0.0135
		X9	0.0057	-0.0068	0.0052	0.0003	0.0089
		X10	0.0116	-0.0043	0.0437	0.0002	0.0078
		X11	-0.0002	-0.0152	-0.0006	0.0007	0.0144
		X12	0.0055	-0.0095	0.0034	0.0007	-0.0165
		X13	0.5084	0.4952	0.5042	0.5305	0.5402
		X14	0.0074	-0.0095	-0.0465	0.0059	0.0674
		X15	0.0017	-0.0135	0.0410	0.0025	0.0398
		X16	-0.0054	-0.0193	-0.0045	0.0013	0.0369

Notes. $\hat{\phi}_j$: valeur de Shapley. S^1 , S^T : indices de Sobol premier ordre et total. Au niveau 1, $\hat{\phi}_j = \text{n.d.}$ (indices Sobol directs).

4 Conclusion

4.1 Apports du stage

Ce stage avait pour objectif d'étudier l'analyse de sensibilité globale dans le cadre particulier des systèmes feed-forward multi-niveaux. Contrairement à une analyse directe entre les entrées initiales et la sortie finale, l'approche développée cherche également à comprendre comment l'influence des variables se propage à travers les différents niveaux du système.

Dans un premier temps, une étude bibliographique a permis de rappeler les principales méthodes d'analyse de sensibilité globale. Les méthodes de screening, notamment la méthode de Morris et les mesures globales fondées sur les dérivées, ont été présentées comme des outils permettant d'identifier rapidement les variables peu influentes. Les indices de Sobol ont ensuite été étudiés en détail, en particulier leur lien avec la décomposition de Hoeffding et leur interprétation en termes de contributions à la variance.

Une attention particulière a également été portée aux valeurs de Shapley et au critère HSIC. Les valeurs de Shapley permettent de répartir une contribution entre plusieurs variables en tenant compte de leurs interactions et de leurs éventuelles dépendances. L'HSIC offre quant à lui une mesure générale de dépendance, capable de détecter des relations non linéaires ou non monotones, ainsi qu'un cadre naturel pour construire des tests d'indépendance. Cette étude a permis de mettre en évidence la complémentarité entre les indices de Sobol, les valeurs de Shapley et les mesures de dépendance fondées sur les noyaux.

Le travail a ensuite porté sur la construction d'une méthode d'analyse hiérarchique adaptée aux systèmes feed-forward. La méthode proposée repose sur les étapes suivantes :

- sélectionner les variables influentes du premier niveau à l'aide des indices de Sobol totaux ;
- reconstruire les sorties intermédiaires à partir d'une estimation non paramétrique de copules conditionnelles ;
- utiliser les valeurs de Shapley pour sélectionner les variables influentes aux niveaux suivants ;
- répéter cette procédure jusqu'à la sortie finale du système ;
- comparer l'analyse hiérarchique à une analyse directe entre les entrées initiales et la sortie finale.

L'utilisation de copules conditionnelles permet de reconstruire des variables intermédiaires en conservant une partie de leur structure de dépendance avec les variables du niveau précédent. La reconstruction est réalisée à partir de pseudo-observations, d'une estimation par noyau de la loi conditionnelle et d'une inversion numérique de la fonction de répartition conditionnelle. La qualité de cette reconstruction est évaluée à l'aide du tau de Kendall, d'ajustements de copules bivariées et de mesures d'erreur relatives.

La méthode a été étudiée sur plusieurs exemples numériques. Les expériences réalisées sur la G-fonction et la fonction de Friedman ont permis de comparer les comportements des indices de Sobol et du critère HSIC dans des situations d'indépendance, de non-linéarité et d'interaction. Le cas avec des entrées dépendantes a également permis de montrer les limites des indices de Sobol classiques et l'intérêt des valeurs de Shapley dans un tel contexte.

La méthode a enfin été appliquée à un système en cascade composé de plusieurs solveurs. Cette application a permis d'étudier séparément l'influence des variables à chaque niveau, puis de comparer ces résultats avec une analyse directe de la sortie finale. L'analyse par niveaux fournit une information complémentaire à l'analyse globale : certaines variables peuvent être influentes à un niveau intermédiaire sans apparaître comme dominantes dans l'analyse directe de la sortie finale. La méthode permet ainsi de distinguer l'importance globale d'une variable de la manière dont son influence se transmet à travers le système.

Un autre apport du stage concerne l'application de ces méthodes à des données de type MARTHE. Ce jeu de données présente notamment des dépendances structurelles entre certaines variables d'entrée. L'utilisation de groupes de variables et de tests d'indépendance fondés sur

l'HSIC a permis d'obtenir des résultats cohérents avec ceux rapportés dans la littérature, tout en évitant dans certains cas la construction préalable d'un métamodèle.

Ces travaux ont également permis de mettre en évidence les limites d'interprétation de certaines mesures. Les indices de Sobol peuvent être interprétés directement comme des contributions à la variance, tandis que l'HSIC mesure une dépendance dans un espace de Hilbert et dépend du choix des noyaux. De même, les valeurs de Shapley ne sont interprétables qu'en fonction de la mesure utilisée pour définir la fonction caractéristique. Ces différences doivent être prises en compte lors de la comparaison des résultats.

4.2 Pistes d'amélioration

Plusieurs améliorations peuvent être envisagées afin de renforcer la méthodologie proposée et d'étendre son domaine d'application.

Quantification de l'incertitude. La méthode développée combine plusieurs étapes d'estimation : estimation des indices de sensibilité, estimation des copules conditionnelles, reconstruction des variables intermédiaires et calcul des valeurs de Shapley. Les erreurs associées à ces différentes étapes peuvent se propager d'un niveau au suivant. Dans ce travail, la qualité de la reconstruction a principalement été évaluée à l'aide d'indicateurs finaux tels que le tau de Kendall et l'erreur relative.

Une amélioration importante consisterait à quantifier explicitement l'incertitude à chaque niveau. Des méthodes de bootstrap pourraient être utilisées pour obtenir des intervalles de confiance pour les indices, les valeurs de Shapley, les paramètres des copules et les indicateurs de reconstruction. Il serait également intéressant de propager plusieurs reconstructions possibles jusqu'à la sortie finale afin d'évaluer directement l'incertitude globale de la méthode.

Choix des seuils de sélection. Les seuils utilisés pour sélectionner les variables influentes sont des choix arbitraires. Ils ne correspondent pas nécessairement à des seuils de significativité statistique et peuvent influencer les variables retenues ainsi que les reconstructions des niveaux suivants.

Il serait donc utile de réaliser une étude de sensibilité aux seuils de sélection. Une autre possibilité consisterait à sélectionner les variables à partir d'intervalles de confiance, de tests statistiques ou d'un critère adaptatif dépendant de la taille de l'échantillon et de la variance de l'estimateur.

Allocation du poids à chaque niveau de la sensibilité des variables C'est une piste qui n'a pas du tout été explorée mais à portée avec la méthode construite pendant ce stage. Il s'agirait d'examiner, pour les variables influentes du système, à quels niveaux du système feed-forward elles agissent, et quantifier ceci à chaque niveau de manière à, dans la même veine que Sobol, sommer à 1 pour avoir la contribution totale. Cette allocation pourrait finalement conduire à une représentation sous forme de masse de sensibilité se déplaçant le long du graphe feed-forward, depuis les entrées initiales jusqu'à la sortie finale.

Par exemple, elle permettrait sur des systèmes multi-physiques de localiser l'optimisation aux niveaux où les variables influentes sont "le plus influentes".

Variables partagées entre plusieurs niveaux. La présence d'une variable partagée, c'est-à-dire une variable intervenant dans plusieurs niveaux du système, constitue une difficulté particulière. Une répartition naïve de cette variable peut conduire à compter plusieurs fois son influence ou, au contraire, à la supprimer d'un niveau où elle joue un rôle important.

Une extension de la méthode devrait proposer une règle systématique pour identifier et traiter ces variables. Les valeurs de Shapley pourraient notamment être utilisées pour attribuer la

contribution d'une variable partagée aux différents niveaux. Une autre possibilité consisterait à considérer explicitement les variables partagées comme des entrées communes dans le graphe du système feed-forward via par exemple des problèmes de point fixe.

Amélioration de l'estimation par noyau. L'estimation non paramétrique par noyau est flexible, mais elle est sensible au choix du noyau et de la bande passante. La règle de Silverman utilisée dans ce travail constitue une première approximation, mais elle n'est pas nécessairement optimale pour toutes les configurations.

Des méthodes de sélection automatique de la bande passante pourraient être étudiées. Il serait également pertinent de comparer plusieurs noyaux, notamment les noyaux gaussien, de Laplace et de Matérn, ainsi que des méthodes de correction des effets de bord sur l'intervalle $[0, 1]$. Pour des dimensions plus élevées, l'utilisation de copules paramétriques, de vine copulas ou de modèles de substitution pourrait permettre de limiter le fléau de la dimension.

Réduction du coût de calcul. La double boucle Monte Carlo utilisée pour l'estimation des valeurs de Shapley peut devenir coûteuse lorsque le nombre de variables ou de niveaux augmente. L'utilisation de permutations aléatoires permet déjà d'éviter l'énumération de toutes les coalitions, mais le nombre de simulations nécessaires reste important.

Plusieurs pistes peuvent être envisagées : réutilisation des mêmes simulations entre différentes coalitions, parallélisation des évaluations, réduction adaptative du nombre de permutations et construction d'un métamodèle pour les sorties intermédiaires.

Validation sur des systèmes plus complexes. La méthode a été étudiée sur des exemples numériques et sur un système en cascade comportant plusieurs niveaux. Une validation complémentaire sur des codes industriels plus coûteux et des systèmes comportant davantage de variables permettrait d'évaluer sa robustesse.

Il serait également intéressant de considérer des systèmes présentant des boucles de rétroaction, des sorties fonctionnelles ou multivariées, ainsi que des niveaux dont les sorties sont elles-mêmes fortement dépendantes. La structure feed-forward facilite la propagation de l'analyse, mais une extension à des graphes plus généraux nécessiterait de revoir la définition des dépendances conditionnelles entre les niveaux.

Ces différentes améliorations permettraient de consolider la méthode proposée, d'en mieux quantifier les limites et de la rendre plus facilement applicable à des systèmes multi-niveaux complexes et coûteux à simuler.

5 Annexes

5.1 HSIC-ANOVA

Les indices HSIC-ANOVA, introduits dans [2], offrent une interprétation plus proche de celle des indices de Sobol, au prix d'hypothèses supplémentaires. La théorie sous-jacente est détaillée dans [18].

5.1.1 Noyaux ANOVA

Définition 11 (Noyau ANOVA). *Un noyau ANOVA est un noyau de la forme*

$$k(x, x') = \prod_{j=1}^p (1 + k_j(x_j, x'_j)),$$

où les k_j sont des noyaux définis positifs sur les composantes marginales.

En développant le produit, on obtient une somme sur tous les sous-ensembles $u \subseteq \{1, \dots, p\}$:

$$k(x, x') = \sum_{u \subseteq \{1, \dots, p\}} \prod_{j \in u} k_j(x_j, x'_j) = \sum_{u \subseteq \{1, \dots, p\}} k_u(x_u, x'_u).$$

Ce noyau est donc une somme de termes d'interaction d'ordre croissant :

$$k(x, x') = 1 + \sum_{i=1}^p k_i(x_i, x'_i) + \sum_{i < j} k_i(x_i, x'_i) k_j(x_j, x'_j) + \dots + \prod_{i=1}^p k_i(x_i, x'_i).$$

5.1.2 Noyau de Sobolev

Un exemple (peut-être le seul ?) de noyau ANOVA par construction sont les noyaux de Sobolev.

Définition 12. *Pour $m \in \mathbb{N}^*$, l'espace de Sobolev d'ordre m sur $[0, 1]$ est défini par*

$$W^m([0, 1]) = \left\{ f : [0, 1] \rightarrow \mathbb{R} \mid f, f', \dots, f^{(m-1)} \text{ absolument continues, } f^{(m)} \in L^2([0, 1]) \right\},$$

muni du produit scalaire

$$\langle f, g \rangle_{W^m} = \sum_{s=0}^{m-1} f^{(s)}(0) g^{(s)}(0) + \int_0^1 f^{(m)}(t) g^{(m)}(t) dt.$$

$W^m([0, 1])$ est un espace de Hilbert à noyau reproduisant, dont le noyau est appelé noyau de Sobolev d'ordre m .

Définition 13 (Noyau de Sobolev d'ordre m). *Le noyau reproduisant de $W^m([0, 1])$ est donné par*

$$k_m^{\text{Sob}}(x, x') = \sum_{s=0}^{m-1} \frac{x^s}{s!} \frac{(x')^s}{s!} + \int_0^1 \frac{(x-t)_+^m}{(m)!} \frac{(x'-t)_+^m}{(m)!} dt,$$

où $(u)_+ = \max(u, 0)$ désigne la partie positive.

Remarque 5. *Dans le cas $m = 1$, le produit scalaire se réduit à*

$$\langle f, g \rangle_{W^1} = f(0) g(0) + \int_0^1 f'(t) g'(t) dt,$$

et le noyau admet l'expression explicite

$$k_1^{\text{Sob}}(x, x') = 1 + \min(x, x')^2 \left(\frac{\max(x, x')}{2} - \frac{\min(x, x')}{6} \right).$$

Structure ANOVA du noyau de Sobolev multivarié. Sur $[0, 1]^p$, le noyau de Sobolev tensorisé

$$k_m^{\text{Sob}}(x, x') = \prod_{j=1}^p k_m^{\text{Sob}}(x_j, x'_j)$$

est un noyau ANOVA au sens de la définition précédente. En posant

$$k_j(x_j, x'_j) = k_m^{\text{Sob}}(x_j, x'_j) - 1, \quad j = 1, \dots, p,$$

on obtient la décomposition

$$k_m^{\text{Sob}}(x, x') = \prod_{j=1}^p (1 + k_j(x_j, x'_j)) = \sum_{u \subseteq \{1, \dots, p\}} \prod_{j \in u} k_j(x_j, x'_j),$$

et le RKHS associé se décompose en somme directe orthogonale

$$\mathcal{H}_{k_m^{\text{Sob}}} = \bigoplus_{u \subseteq \{1, \dots, p\}} \mathcal{H}_{k_u},$$

où $\mathcal{H}_{k_u}$ est le RKHS de noyau $k_u(x_u, x'_u) = \prod_{j \in u} k_j(x_j, x'_j)$.

5.1.3 Décomposition HSIC-ANOVA

[3] montre que, muni d'un noyau ANOVA sur $\mathcal{X} = [0, 1]^p$, le HSIC admet une décomposition additive en contributions d'interaction.

Définition 14 (HSIC d'interaction pur). *Pour tout $u \neq \emptyset$, la contribution d'interaction pure de X_u sur Y est*

$$\text{HSIC}_u(X_u, Y) = \sum_{v \subseteq u} (-1)^{|u|-|v|} \widetilde{\text{HSIC}}_v(X_v, Y).$$

Théorème 3 (Décomposition HSIC-ANOVA). *Sous la condition de centrage des noyaux marginaux, le HSIC se décompose en somme de contributions d'interaction pures :*

$$\text{HSIC}(X, Y) = \sum_{\emptyset \neq u \subseteq \{1, \dots, p\}} \text{HSIC}_u(X_u, Y).$$

Cette décomposition est additive et chaque terme $\text{HSIC}_u(X_u, Y) \geq 0$ mesure l'effet d'interaction d'ordre $|u|$ de X_u sur Y , indépendamment des effets d'ordre inférieur.

5.1.4 Indices associés

Les indices associés sont définis par

$$S_u^{\text{HSIC-ANOVA}} = \frac{\text{HSIC}_u(X_u, Y)}{\text{HSIC}(X, Y)}.$$

Ils vérifient

$$S_u^{\text{HSIC-ANOVA}} \geq 0, \quad \sum_u S_u^{\text{HSIC-ANOVA}} = 1.$$

En pratique, on se restreint souvent aux effets du premier ordre $u = \{k\}$. Si certaines entrées sont structurellement dépendantes, par exemple $X_{k_1}, X_{k_2}, X_{k_3}$, on peut les regrouper en bloc et prendre $u = \{k_1, k_2, k_3\}$, ce qui mesure leur contribution jointe.

5.2 HSIC-Shapley

De nouveaux indices HSIC-Shapley ont été introduits par [3]. Ils reprennent les idées de Sobol-Shapley en les transposant à un cadre RKHS, avec des mesures à noyau de la dépendance. Avant cela, il est utile d'introduire la MMD (*Maximum Mean Discrepancy*), une mesure de divergence entre distributions compatible avec le cadre RKHS.

5.2.1 Rappel sur la MMD

Définition 15 (Plongement d'une distribution). *Soit k un noyau caractéristique associé au RKHS $\mathcal{H}_k$. Le plongement d'une distribution P est défini par*

$$\mu_P := \mathbb{E}_{X \sim P}[k(\cdot, X)].$$

Définition 16 (MMD). *La MMD entre deux distributions P et Q est définie par*

$$\text{MMD}^2(P, Q) = \|\mu_P - \mu_Q\|_{\mathcal{H}_k}^2.$$

Elle admet aussi l'expression

$$\text{MMD}^2(P, Q) = \mathbb{E}_{X, X' \sim P}[k(X, X')] - 2\mathbb{E}_{X \sim P, Z \sim Q}[k(X, Z)] + \mathbb{E}_{Z, Z' \sim Q}[k(Z, Z')].$$

Comme le noyau est caractéristique, on a

$$\text{MMD}^2(P, Q) = 0 \iff P = Q.$$

La MMD généralise ainsi l'indice de Borgonovo dans un cadre non paramétrique.

5.2.2 Définition des indices

Les effets de Shapley à noyau sont alors définis en version MMD-Shapley et HSIC-Shapley. Pour tout $l \in \{1, \dots, d\}$, on peut écrire :

$$\text{Sh}_l^{\text{MMD}} = \frac{1}{\text{MMD}_{\text{tot}}^2} \frac{1}{d} \sum_{A \subseteq [d] \setminus \{l\}} \frac{1}{\binom{d-1}{|A|}} \left(\mathbb{E}_{X_{A \cup \{l\}}} [\text{MMD}^2(P_Y, P_{Y|X_{A \cup \{l\}}})] - \mathbb{E}_{X_A} [\text{MMD}^2(P_Y, P_{Y|X_A})] \right), \quad (44)$$

$$\text{Sh}_l^{\text{HSIC}} = \frac{1}{\text{HSIC}(X, Y)} \frac{1}{d} \sum_{A \subseteq [d] \setminus \{l\}} \frac{1}{\binom{d-1}{|A|}} (\text{HSIC}(X_{A \cup \{l\}}, Y) - \text{HSIC}(X_A, Y)). \quad (45)$$

Grâce aux propriétés classiques des valeurs de Shapley, ces effets sont normalisés :

$$\sum_{l=1}^d \text{Sh}_l^{\text{MMD}} = 1 \quad \text{et} \quad \sum_{l=1}^d \text{Sh}_l^{\text{HSIC}} = 1.$$

5.3 Suite du cas du dataset MARTHE

5.3.1 HSIC-ANOVA

On a nos groupes indépendants déjà prêts, donc on peut directement calculer nos indices. On prend toujours les mêmes noyaux, à la différence qu'on les a rendus ANOVA. La raison pour laquelle on avait choisi la somme et le produit est que ce sont les rares opérations qui gardent ANOVA la transformation, comme montré dans [18]. Il y a quand même la subtilité qu'on veut les interactions, donc intuitivement il semble plus logique de prendre des noyaux produits sur les groupes (en vertu de leur décomposition en somme d'interactions). C'est pourquoi on va se

limiter à 2 cas : RBF Anova produit, et Matérn 3/2 ANOVA produit. La différence en pratique du RBF et du Matérn est que le RBF est beaucoup plus lisse, et donc le Matérn serait peut-être plus adapté aux phénomènes physiques.

L'indice qu'on estime est toujours le même, il n'y a rien à changer sauf le noyau dans le code. On trouve donc les indices suivants :




FIGURE 33 – Indices HSIC ANOVA (R^2 -HSIC) avec comme noyaux de groupe des produits de RBF ANOVA.




FIGURE 34 – Indices HSIC ANOVA (R^2 -HSIC) obtenus avec comme noyaux de groupe des produits de Matérn 3/2 ANOVA.




FIGURE 35 – p-valeurs du test de permutation avec comme noyaux de groupes des produits de RBF ANOVA.




FIGURE 36 – p-valeurs du test de permutation avec comme noyaux de groupes des produits de Matern 3/2 ANOVA.

On voit que dans le contexte de HSIC-ANOVA, du moins au niveau des tests de p-valeurs, il y a beaucoup de nouvelles variables d'entrées qui sont comptées comme significatives. Ceci permet de mettre en alerte qu'une valeur faible du HSIC est rédhitoire. On a quand même fait une étude ici avec 2 noyaux assez proches, mais un noyau qui serait sensible aux outliers aussi aurait peut-être capté ces variables dès le début, rien qu'avec l'indice de R^2 -HSIC.

En tout cas, on peut se rassurer sur notre méthode car on trouve les mêmes résultats que [21], surtout au niveau des variables retenues malgré qu'eux ont du passer par un métamodèle

et nous non.

5.3.2 HSIC-Shapley

Une autre manière de contourner les dépendances tout en gardant le HSIC est donc de passer par la théorie des jeux. C'est ce qu'on a fait sur le dataset MARTHE, et pour des questions de lisibilité on ne va commenter que sur 2 sorties sur 10.




FIGURE 37 – Indices de Shapley avec comme fonction caractéristique le HSIC (U-stat ici), sur le dataset MARTHE et sa sortie p38. (Code personnel du HSIC-Shapley avec la méthode d'approximation de Song, non implémenté dans `sensitivity`).

Première observation : des indices négatifs alors que le HSIC est positif? C'est normal, en voyant la définition des indices HSIC-Shapley : ça veut juste dire que dans les itérations de la somme, le fait d'ajouter la variable en question dans le groupe baisse le gain au lieu de l'augmenter. Sinon, on trouve des résultats cohérents avec ce qu'on trouvait avant. Même si ça n'apparaît pas sous forme de groupes, *i1*, *i3*, *d2*, *dt2* apparaissent quand même comme ayant des valeurs positives.

L'apparition des valeurs négatives pour un indice de sensibilité remet tout de même en question l'idée qu'on avait de "indice proche de 0, variable qui n'influe pas". Il faut voir comment interpréter ces valeurs négatives. Une manière intuitive en prenant en compte le contexte de théorie des jeux serait de dire que c'est comme avoir un joueur qui joue contre son camp, mais il se pose le problème de transposer "jouer contre son camp" dans le contexte probabiliste et de l'analyse de sensibilité : est-ce que ça apporte des contributions négatives aux variables influentes? est-ce que c'est une question de valeur absolue? Ca reste des questions pour plus tard..

Essayons tout de même de regarder la figure suivante :




FIGURE 38 – Indices de Shapley avec comme fonction caractéristique le HSIC, sur le dataset MARTHE et sa sortie p102K.

Ici, on a un léger effet de $i3$, mais tout est porté par $kd2$ qui a un indice qui vaut 1,751. On rappelle que les indices HSIC-Shapley pour chaque sortie somment à 1, et c'était vérifié par le calcul. On voit aussi qu'en contrepartie, les valeurs négatives sont bien plus loin dans les négatifs que pour la sortie $p38$. On peut se dire que c'est pour balancer la grande valeur de $kd2$. En effet, sur les 8 autres sorties, dès lors qu'on a un indice dépassant 1, on a presque systématiquement des valeurs très négatives.

En effet, le fait de sommer à 1 force ces indices à compenser la grande valeur positive par une aussi grande valeur négative. Il serait plausible d'avoir 5 indices qui valent 10,2 et 5 indices qui valent -10. Peut-être si on normalisait et qu'on utilisait comme fonction caractéristique le R^2_{HSIC} , ces valeurs très négatives n'existeraient plus ?

Références

- [1] Javier CASTRO, Daniel GÓMEZ et Juan TEJADA. « Polynomial calculation of the Shapley value based on sampling ». In : *Computers & operations research* 36.5 (2009), p. 1726-1730.
- [2] Sebastien DA VEIGA. « Global sensitivity analysis with dependence measures ». en. In : *Journal of Statistical Computation and Simulation* 85.7 (mai 2015), p. 1283-1305. ISSN : 0094-9655, 1563-5163. DOI : 10.1080/00949655.2014.945932. URL : <http://www.tandfonline.com/doi/abs/10.1080/00949655.2014.945932> (visité le 03/06/2026).
- [3] Sébastien DA VEIGA. *Kernel-based ANOVA decomposition and Shapley effects – Application to global sensitivity analysis*. en. Jan. 2021. URL : <https://arxiv.org/abs/2101.05487v1> (visité le 03/06/2026).
- [4] Mohamed Reda EL AMRI et Amandine MARREL. « MORE POWERFUL HSIC-BASED INDEPENDENCE TESTS, EXTENSION TO SPACE-FILLING DESIGNS AND FUNCTIONAL DATA ». en. In : *Int. J. Uncertainty Quantification* 14.2 (2024), p. 69-98. ISSN : 2152-5080. DOI : 10.1615/Int.J.UncertaintyQuantification.v14.i2.40. URL : <https://www.dl.begellhouse.com/journals/52034eb04b657aea,6df398e3676f7081,3c2d6c4b75ab091f.html> (visité le 03/06/2026).
- [5] Noé FELLMANN. « Sensitivity analysis for black-box Bayesian optimisation under constraints and in presence of uncertainties : sensitivity analysis of random sets ». Theses. Ecole Centrale de Lyon, déc. 2024. DOI : 10.70675/b032f21dz4622z4a5dz847aze76753436e34. URL : <https://theses.hal.science/tel-05014682>.
- [6] Jerome H FRIEDMAN. « Multivariate adaptive regression splines ». In : *The annals of statistics* 19.1 (1991), p. 1-67.
- [7] Fabrice GAMBOA et al. *Sensitivity analysis for multidimensional and functional outputs*. 2013. arXiv : 1311.1797 [stat.AP]. URL : <https://arxiv.org/abs/1311.1797>.
- [8] Arthur GRETTON et al. « A Kernel Statistical Test of Independence ». In : *Advances in Neural Information Processing Systems*. T. 20. Curran Associates, Inc., 2007. URL : https://proceedings.neurips.cc/paper_files/paper/2007/hash/d5cfead94f5350c12c322b5b664544c1-Abstract.html (visité le 03/06/2026).
- [9] Bertrand IOOSS et Paul LEMAÎTRE. « A Review on Global Sensitivity Analysis Methods ». en. In : *Uncertainty Management in Simulation-Optimization of Complex Systems*. Sous la dir. de Gabriella DELLINO et Carlo MELONI. T. 59. Series Title : Operations Research/Computer Science Interfaces Series. Boston, MA : Springer US, 2015, p. 101-122. ISBN : 978-1-4899-7546-1 978-1-4899-7547-8. DOI : 10.1007/978-1-4899-7547-8_5. URL : https://link.springer.com/10.1007/978-1-4899-7547-8_5 (visité le 03/06/2026).
- [10] Bertrand IOOSS et Clémentine PRIEUR. *Shapley effects for sensitivity analysis with correlated inputs : comparisons with Sobol' indices, numerical estimation and applications*. 2019. arXiv : 1707.01334 [math.ST]. URL : <https://arxiv.org/abs/1707.01334>.
- [11] Sergei KUCHERENKO et al. « The identification of model effective dimensions using global sensitivity analysis ». In : *Reliability Engineering & System Safety* 96.4 (2011), p. 440-449.
- [12] Matthias De LOZZO et Amandine MARREL. *New improvements in the use of dependence measures for sensitivity analysis and screening*. 2014. arXiv : 1412.1414 [stat.ME]. URL : <https://arxiv.org/abs/1412.1414>.
- [13] Roger B NELSEN. *An introduction to copulas*. Springer, 2006.
- [14] Art B. OWEN. « Sobol' Indices and Shapley Value ». en. In : *SIAM/ASA J. Uncertainty Quantification* 2.1 (jan. 2014), p. 245-251. ISSN : 2166-2525. DOI : 10.1137/130936233. URL : <http://epubs.siam.org/doi/10.1137/130936233> (visité le 03/06/2026).

- [15] Mathis PASQUIER. « Quantification d’incertitudes pour la dispersion turbulente de polluants liés au trafic routier à l’échelle micro-urbaine ». Theses. Aix Marseille Université (AMU), déc. 2023. URL : <https://theses.hal.science/tel-04866373>.
- [16] Francois SANSON, Olivier LE MAITRE et Pietro Marco CONGEDO. « Systems of Gaussian process models for directed chains of solvers ». In : *Computer Methods in Applied Mechanics and Engineering* 352 (2019), p. 32-55.
- [17] Gabriel SARAZIN. « Analyse de sensibilité fiabiliste en présence d’incertitudes épistémiques introduites par les données d’apprentissage ». fr. In : (2022).
- [18] Gabriel SARAZIN et Amandine MARREL. « New insights into the feature maps of Sobolev kernels : application in global sensitivity analysis ». en. In : (2023).
- [19] I. M. SOBOL et S. KUCHERENKO. « Derivative based global sensitivity measures and their link with global sensitivity indices ». In : *Mathematics and Computers in Simulation* 79.10 (juin 2009), p. 3009-3017. ISSN : 0378-4754. DOI : 10.1016/j.matcom.2009.01.023. URL : <https://www.sciencedirect.com/science/article/pii/S0378475409000354> (visité le 03/06/2026).
- [20] Eunhye SONG, Barry L. NELSON et Jeremy STAUM. « Shapley Effects for Global Sensitivity Analysis : Theory and Computation ». en. In : *SIAM/ASA J. Uncertainty Quantification* 4.1 (jan. 2016), p. 1060-1083. ISSN : 2166-2525. DOI : 10.1137/15M1048070. URL : <http://epubs.siam.org/doi/10.1137/15M1048070> (visité le 03/06/2026).
- [21] Elena VOLKOVA, Bertrand IOOSS et François VAN DORPE. « Global sensitivity analysis for a numerical model of radionuclide migration from the RRC “Kurchatov Institute” radwaste disposal site ». In : *Stochastic Environmental Research and Risk Assessment* 22.1 (2008), p. 17-31.
- [22] Can XU et al. « Mapping-Based Hierarchical Sensitivity Analysis for Multilevel Systems With Multidimensional Correlations ». en. In : *Journal of Mechanical Design* 143.1 (jan. 2021), p. 011707. ISSN : 1050-0472, 1528-9001. DOI : 10.1115/1.4047689. URL : <https://asmedigitalcollection.asme.org/mechanicaldesign/article/143/1/011707/1084968/Mapping-Based-Hierarchical-Sensitivity-Analysis> (visité le 03/06/2026).